Schriftliche Ausarbeitung zum Seminarvortrag

Einführung in die Kerndichteschätzung

Yavuzâlp Dal

Stand: 14. Dezember 2025

1 Einleitung & Motivation

Inhaltsverzeichnis

1 Einleitung & Motivation 1

2 Der Rosenblatt-Schätzer (Die theoretische Basis) 2

3 Das Histogramm (Der Klassiker) 2

4 Kernschätzer (Kernel Density Estimation - KDE) 2

5 Nichtparametrische Regression 3

5.1 Watson-Nadaraya Schätzer (Allgemeine Regression) 3

5.2 Robuste Lineare Regression (Theil-Schätzer) 3

6 Zusammenfassung für das Seminar 4

Warum nichtparametrisch?

Klassische parametrische Verfahren (z. B. unter Annahme einer Normalverteilung) sind oft zu starr. Wenn die wahre Verteilung unbekannt ist, liefert die nichtparametrische Schätzung der Dichtefunktion f oft bessere Einblicke in die Datenstruktur (z. B. Schiefe, Multimodalität) als die reine Verteilungsfunktion F.

Zielsetzung

Wir suchen eine Annäherung an den Wert $f(x)$ an einer Stelle x, ohne eine bestimmte parametrische Familie vorauszusetzen.

2 Der Rosenblatt-Schätzer (Die theoretische Basis)

Der Ausgangspunkt für moderne Dichteschätzer ist der Ansatz von Rosenblatt (1956).

- **Idee:** Da $f(x) = F'(x)$, nutzt man den Differenzenquotienten der empirischen Verteilungsfunktion F_n.
- **Der Schätzer:**

$$f_n(x) = \frac{F_n(x+h) - F_n(x-h)}{2h} \tag{1}$$

  Dies entspricht der relativen Häufigkeit von Datenpunkten im Intervall $(x-h, x+h]$, geteilt durch die Länge $2h$.
- **Konsistenz:** Damit der Schätzer gegen die wahre Dichte konvergiert (MSE $\to 0$), muss für den Stichprobenumfang $n \to \infty$ gelten:
  1. Die Bandbreite $h \to 0$ (um den Bias zu reduzieren).
  2. Das Produkt $nh \to \infty$ (um die Varianz zu reduzieren).

3 Das Histogramm (Der Klassiker)

Das Histogramm ist die älteste Methode, hat aber methodische Schwächen für präzise Analysen.

- **Funktionsweise:** Zerlegung des Datenraums in Boxen (Bins) der Breite h. Die Höhe der Box entspricht der relativen Häufigkeit $\frac{n_k}{n}$ normiert durch h.
- **Probleme:**
  1. **Unstetigkeit:** Die geschätzte Dichte ist eine Treppenfunktion, obwohl die wahre Natur oft glatt (stetig differenzierbar) ist.
  2. **Subjektivität:** Form und Aussage hängen stark vom Startpunkt x_0 und der Klassenbreite h ab.
- **Optimale Bandbreite (h):** Die Wahl von h ist ein Balanceakt (Bias-Varianz-Tradeoff). Ein zu kleines h erzeugt eine „zackige“ Kurve (hohe Varianz), ein zu großes h glättet wichtige Details weg (hoher Bias).
  - *Faustregel (Scott):* $h \approx 3.49sn^{-1/3}$ (basiert auf Normalverteilungsannahme).
  - *Robuste Regel (Freedman-Diaconis):* Nutzt den Interquartilsabstand, um Ausreißer weniger zu gewichten:

$$h^* = 2(x_{0.75} - x_{0.25})n^{-1/3}$$

4 Kernschätzer (Kernel Density Estimation - KDE)

Um die Glattheit zu garantieren, verallgemeinert man den Rosenblatt-Ansatz durch sogenannte Kerne.

- **Der Schätzer:**

$$\hat{f}n(x) = \frac{1}{nh} \sum i = 1^n K\left(\frac{x - X_i}{h}\right) \tag{2}$$

  Jeder Datenpunkt X_i bekommt eine kleine „Glockenkurve“ (Kern K), und die Summe dieser Kurven ergibt die Gesamtdichte.
- **Wahl des Kerns (K):** Der Kern muss zu 1 integrieren ($\int K(x)dx = 1$). Gängige Kerne sind:
  - *Rechteck-Kern:* Entspricht dem naiven Rosenblatt-Schätzer.
  - *Gauß-Kern:* Standardnormalverteilung (glatt und differenzierbar).

- *Epanechnikov-Kern:* Parabolisch; dieser Kern ist theoretisch optimal, da er den integrierten mittleren quadratischen Fehler (IMSE) minimiert.
- **Bandbreitenwahl (Silverman's Rule):** Die Bandbreite h ist viel entscheidender als die Kernform. Eine Standard-Faustformel (für Gauß-Kerne) ist:

$$h_{opt} \approx 1.06\sigma n^{-1/5} \tag{3}$$

Oft wird σ robust durch den Quartilsabstand geschätzt ($\hat{h}_{opt} \approx 0.79Qn^{-1/5}$), um Oversmoothing zu vermeiden.

5 Nichtparametrische Regression

Hier verlassen wir die Dichteschätzung und betrachten den Zusammenhang zwischen zwei Variablen X und Y: $Y = m(X) + \epsilon$.

5.1 Watson-Nadaraya Schätzer (Allgemeine Regression)

Wenn wir keine Formel für $m(x)$ kennen, schätzen wir den Wert als gewichteten Mittelwert der umliegenden Y-Werte:

$$\hat{m}WN(x) = \frac{\sum i = 1^n K\left(\frac{x-X_i}{h}\right) Y_i}{\sum_{i=1}^n K\left(\frac{x-X_i}{h}\right)} \tag{4}$$

Datenpunkte X_i, die nahe an x liegen, erhalten durch den Kern K ein hohes Gewicht.

5.2 Robuste Lineare Regression (Theil-Schätzer)

Selbst wenn wir einen linearen Trend ($Y = \alpha + \beta X$) vermuten, ist die klassische Methode der kleinsten Quadrate (OLS) anfällig für Ausreißer. Das Buch stellt robuste Alternativen vor:

1. **Theil-Methode I:** Man teilt die Daten in zwei Hälften und berechnet Steigungen zwischen Paaren $(i, i + n/2)$. Der Schätzer ist der Median dieser Steigungen.

2. **Theil-Sen-Schätzer (Methode II):** Dies ist die präzisere Variante. Man berechnet die Steigung zwischen **allen** möglichen Paaren $i < j$:

$$H_{ij} = \frac{Y_j - Y_i}{X_j - X_i} \tag{5}$$

   Der Schätzer für den Anstieg β ist der **Median** all dieser Steigungen (H_{ij}). Das macht ihn extrem robust.

3. **Hypothesentests:** Zum Testen von β wird auf rangbasierte Verfahren wie Kendalls τ (Tau) zurückgegriffen, da diese verteilungsfrei sind.

6 Zusammenfassung für das Seminar

- **Flexibilität:** Nichtparametrische Methoden (KDE, Kernel-Regression) passen sich den Daten an („let the data speak“) und zwingen ihnen keine Form auf.
- **Parameter h:** Die Wahl der Bandbreite ist der kritischste Schritt. Es ist ein Kompromiss zwischen Rauschen (zu kleines h) und Informationsverlust (zu großes h).
- **Robustheit:** Verfahren wie der Theil-Sen-Schätzer bieten mächtige Alternativen zur klassischen Regression, besonders wenn Daten Ausreißer enthalten oder nicht normalverteilt sind.