Schriftliche Ausarbeitung zum Seminarvortrag

Einführung in die Kerndichteschätzung

Yavuzâlp Dal

Stand: 1. März 2026

Inhaltsverzeichnis

1 Einleitung und Motivation **2**

2 Der Schätzer von Rosenblatt (Die theoretische Basis) **3**

3 Das Histogramm (Der Klassiker) **3**

4 Kerndichteschätzung (Kernel Density Estimation – KDE) **5**
4.1 Definition und Funktionsweise 5
4.2 Anforderungen an den Kern 6
4.3 Wahl des Kerns 6
4.4 Statistische Eigenschaften und Bandbreitenwahl 7
4.5 KDE als Faltung 9

5 Nichtparametrische Regression **10**
5.1 Nadaraya-Watson-Schätzer (Allgemeine Regression) 10
5.2 Robuste Lineare Regression (Theil-Schätzer) 11

6 Zusammenfassung und Fazit **12**

1 Einleitung und Motivation

Die Analyse von Verteilungen ist ein zentraler Bestandteil der Statistik. In der klassischen *parametrischen* Statistik wird häufig angenommen, dass die zugrundeliegende Verteilung einer bekannten Familie angehört, beispielsweise der Normalverteilung. Das Ziel beschränkt sich dort darauf, wenige Parameter wie den Erwartungswert μ oder die Varianz σ^2 zu schätzen. Diese Methodik bietet den Vorteil der mathematischen Einfachheit und der effizienten Parameterschätzung bei kleinen Stichprobenumfängen, sofern die Modellannahmen erfüllt sind.

Warum nichtparametrisch?

Dieser Ansatz ist jedoch problematisch, wenn die wahre Verteilung unbekannt ist oder nicht den theoretischen Annahmen entspricht (z. B. bei Schiefe, Multimodalität oder *Heavy Tails* (schwere Ränder)). Klassische parametrische Verfahren sind oft zu starr und führen zu fehlerhaften Interpretationen, wenn die Modellannahmen verletzt sind.

Ferner können wir eine Verteilung normalerweise nicht beweisen – wir nehmen sie lediglich an. Folglich erzeugen wir hier eine extreme Kopplung zwischen (potentiell fehlerhaften) Interpretationen und unserer Schätzung. Diese Abhängigkeit kann zu systematischen Fehlern führen: Wird beispielsweise Normalität fälschlicherweise angenommen, können Konfidenzintervalle oder Hypothesentests irreführende Ergebnisse liefern. Offensichtlich ist es folglich für eine produktive Arbeit sinnvoll, diese Kopplung möglichst abzuschwächen; wobei wir im Nachfolgenden sehen werden, dass sich bestimmte (schwache) Annahmen wie beispielsweise die Stetigkeit nicht zwingend vermeiden lassen, jedoch deren Einfluss i.d.R. nicht zu groß ist.

Die *nichtparametrische Dichteschätzung* verzichtet auf die Zugehörigkeit zu einer starren parametrischen Familie. Stattdessen wird lediglich angenommen, dass die Dichte f gewisse Glattheitseigenschaften, wie etwa Stetigkeit oder Differenzierbarkeit, erfüllt. Diese Flexibilität ermöglicht es, komplexere Strukturen in den Daten zu erfassen, ohne vorab eine spezifische Verteilungsfamilie festlegen zu müssen.

Wichtige Anmerkung: Hierbei ist zu betonen, dass das Ziel nicht die vollständige Auflösung der Kopplung zwischen Annahmen und Schätzung ist – dies wäre auch gar nicht möglich. Vielmehr möchten wir diese Kopplung *abschwächen*, indem wir nur minimale Annahmen (wie Stetigkeit oder Glattheit) treffen, statt eine spezifische parametrische Familie vorauszusetzen.

Zielsetzung

Ziel ist es, eine Annäherung an den Wert $f(x)$ an einer Stelle x allein aus den Daten zu gewinnen, ohne eine bestimmte parametrische Familie vorauszusetzen („Let the data speak“). Die nichtparametrische Dichteschätzung findet breite Anwendung in der explorativen Datenanalyse, der Mustererkennung und überall dort, wo die Verteilungsform a priori unbekannt ist oder nur schwach strukturierte Annahmen getroffen werden sollen.

2 Der Schätzer von Rosenblatt (Die theoretische Basis)

Historisch betrachtet bildet der Ansatz von Rosenblatt [Ros56] (1956) das Fundament moderner Dichteschätzer. Er motiviert sich aus dem fundamentalen Zusammenhang zwischen der Dichtefunktion f und der Verteilungsfunktion F, wobei gilt: $F'(x) = f(x)$ (sofern F differenzierbar ist). Diese Beziehung legt nahe, die Ableitung durch einen Differenzenquotienten zu approximieren und die unbekannte Verteilungsfunktion durch ihre empirische Version zu ersetzen.

- **Idee:** Da $f(x) = F'(x)$, nutzt man den Differenzenquotienten der empirischen Verteilungsfunktion F_n. Der Differentialquotient lässt sich approximieren durch:

$$f(x) \approx \frac{F(x+h) - F(x-h)}{2h} \tag{1}$$

  Diese symmetrische Form des Differenzenquotienten liefert im Allgemeinen präzisere Approximationen als einseitige Differenzen und reduziert systematische Verzerrungen erster Ordnung.
- **Der Schätzer:** Ersetzt man die unbekannte Verteilungsfunktion F durch die empirische Verteilungsfunktion F_n, erhält man den **Rosenblatt-Schätzer**:

$$f_n(x) = \frac{F_n(x+h) - F_n(x-h)}{2h} \tag{2}$$

  Intuitiv zählt dieser Schätzer die relative Häufigkeit der Stichprobenwerte, die in das Intervall $(x-h, x+h]$ fallen, und normiert diese durch die Breite $2h$. Anschaulich handelt es sich um ein „gleitendes Histogramm“. Er entspricht, wie wir später sehen werden, einem Spezialfall der Kernschätzung mit einem Rechteck-Kern. Im Gegensatz zum klassischen Histogramm, das den Datenraum in feste, nicht überlappende Intervalle unterteilt, wird hier für jeden Punkt x ein eigenes, um x zentriertes Intervall betrachtet.
- **Konsistenz:** Damit der Schätzer gegen die wahre Dichte konvergiert (MSE $\to 0$), muss für den Stichprobenumfang $n \to \infty$ gelten:
  1. Die Bandbreite $h \to 0$ (um den Bias zu reduzieren). Dies stellt sicher, dass die Approximation des Differentialquotienten immer genauer wird.
  2. Das Produkt $nh \to \infty$ (um die Varianz zu reduzieren). Dies garantiert, dass in jedem Intervall $(x-h, x+h]$ im Mittel genügend Beobachtungen liegen, damit der Schätzer stabilisiert wird.

  Diese beiden Bedingungen stehen in einem natürlichen Spannungsverhältnis: Während die erste Bedingung ein kleines h fordert, verlangt die zweite, dass h nicht zu schnell gegen Null konvergiert. Ein typisches asymptotisches Regime, das beide Anforderungen erfüllt, ist $h \sim n^{-\alpha}$ mit $0 < \alpha < 1$.

3 Das Histogramm (Der Klassiker)

Das Histogramm ist die älteste und bekannteste Methode der Dichteschätzung, hat aber methodische Schwächen für präzise Analysen. Der Datenraum wird hierbei in disjunkte

Intervalle (Klassen/Bins) B_k der Breite h unterteilt. Die Einfachheit des Histogramms hat es zu einem Standard-Werkzeug der explorativen Datenanalyse gemacht, und es findet breite Anwendung in der Praxis. Seine Stärke liegt in der unmittelbaren Interpretierbarkeit und der effizienten Berechnung, insbesondere bei großen Datensätzen.

- **Funktionsweise:** Zerlegung des Datenraums in Boxen (Bins) der Breite h. Die Höhe der Box entspricht der relativen Häufigkeit $\frac{n_k}{n}$ normiert durch h. Der Histogrammschätzer ist definiert als:
$$\hat{f}_H(x) = \frac{1}{nh} \sum_k n_k \mathbb{1}_{B_k}(x), \tag{3}$$
wobei n_k die Anzahl der Beobachtungen im k-ten Intervall ist und $\mathbb{1}_{B_k}$ die Indikatorfunktion darstellt. Die Normierung durch nh stellt sicher, dass $\int \hat{f}_H(x)\,dx = 1$ gilt, womit der Schätzer eine gültige Wahrscheinlichkeitsdichte darstellt.
- **Probleme:** Trotz seiner Einfachheit weist das Histogramm gravierende Nachteile auf:
  1. **Unstetigkeit:** Die geschätzte Dichte ist eine Treppenfunktion, obwohl die wahre Dichte f oft glatt (stetig differenzierbar) ist. An den Intervallgrenzen entstehen abrupte Sprünge, die keine reale Eigenschaft der zugrundeliegenden Verteilung widerspiegeln, sondern lediglich ein Artefakt der Diskretisierung darstellen.
  2. **Subjektivität:** Form und Aussage hängen stark vom Startpunkt x_0 (Gitterverschiebung) und der Klassenbreite h ab. Eine Verschiebung des Gitters um einen kleinen Betrag kann zu einem völlig anderen visuellen Eindruck führen. Diese Instabilität ist besonders problematisch, wenn Entscheidungen auf Basis des Histogramms getroffen werden sollen.
  3. **Lokale Leere:** In Bereichen mit wenigen Datenpunkten können einzelne Bins leer sein, was zu Nullstellen in der geschätzten Dichte führt, obwohl die wahre Dichte dort positiv sein könnte.
- **Optimale Bandbreite (h):** Die Wahl von h ist ein Balanceakt (Bias-Varianz-Tradeoff). Ein zu kleines h erzeugt eine „zackige“ Kurve (hohe Varianz), ein zu großes h glättet wichtige Details weg (hoher Bias). Im Extremfall $h \to 0$ würde jeder Datenpunkt in seinem eigenen Bin liegen, was zu einer stark verrauschten Schätzung führt. Umgekehrt würde $h \to \infty$ alle Daten in einem einzigen Bin zusammenfassen und keinerlei Information über die Verteilungsstruktur liefern.
  - *Faustregel (Scott [Sco79]):* $h \approx 3.49\, s\, n^{-1/3}$ (basiert auf Normalverteilungsannahme). Diese Regel ist einfach anzuwenden und liefert in vielen praktischen Situationen akzeptable Ergebnisse, insbesondere wenn die Daten nicht zu stark von der Normalverteilung abweichen.
  - *Robuste Regel (Freedman-Diaconis [FD81]):* Nutzt den Interquartilsabstand, um Ausreißer weniger zu gewichten:
  $$h^* = 2(x_{0.75} - x_{0.25})n^{-1/3}$$
  Diese Variante ist robuster gegenüber Ausreißern, da der Interquartilsabstand weniger empfindlich auf extreme Werte reagiert als die Standardabweichung.

Um diese Mängel zu beheben, wurden die Kernschätzer entwickelt, die eine glattere und flexiblere Anpassung ermöglichen. Die Grundidee besteht darin, die harten Intervallgrenzen des Histogramms durch weiche Gewichtungen zu ersetzen.

4 Kerndichteschätzung (Kernel Density Estimation – KDE)

4.1 Definition und Funktionsweise

Um die Glattheit zu garantieren, verallgemeinert die Kerndichteschätzung den Rosenblatt-Ansatz [Ros56; Par62] und behebt die Unstetigkeitsprobleme des Histogramms. Anstatt Beobachtungen nur in starren Boxen zu zählen, gewichtet man sie mittels einer glatten Funktion K, dem sogenannten Kern. Diese Verallgemeinerung ermöglicht kontinuierliche und differenzierbare Dichteschätzungen.

- **Der Schätzer:**

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right) \tag{4}$$

  Hierbei ist $h > 0$ der Glättungsparameter (Bandbreite), n der Stichprobenumfang und K die Kernfunktion. Die Bandbreite h kontrolliert, wie stark jeder Datenpunkt in seiner Umgebung „verschmiert“ wird: Ein kleines h führt zu einer Schätzung, die eng an den beobachteten Datenpunkten haftet, während ein großes h eine stärkere Glättung bewirkt.
- **Anschauliche Interpretation:** Das Vorgehen lässt sich als „Summe von Hügeln“ verstehen: Über jedem Datenpunkt X_i wird eine Kernfunktion (z. B. eine Glockenkurve) platziert. Die Breite dieser „Hügel“ wird durch h gesteuert. An einer Stelle x werden die Werte aller lokalen Kerne aufsummiert und durch nh geteilt, damit die Gesamtfläche unter der Kurve genau 1 ergibt – so entsteht eine gültige Wahrscheinlichkeitsdichte.
- **Beziehung zum Rosenblatt-Schätzer:** Der Rosenblatt-Schätzer lässt sich als Spezialfall der Kerndichteschätzung mit dem Rechteck-Kern auffassen:

$$K_{\text{Rechteck}}(u) = \begin{cases} \frac{1}{2} & \text{falls } |u| \leq 1 \\ 0 & \text{sonst} \end{cases} \tag{5}$$

  Mit diesem Kern gewichtet die KDE alle Punkte im Intervall $(x - h, x + h]$ gleich, was genau der Vorgehensweise des Rosenblatt-Schätzers entspricht.

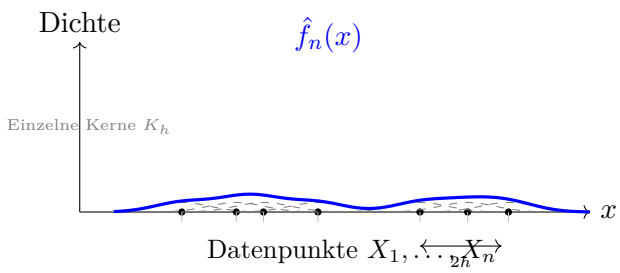

4.2 Anforderungen an den Kern

Damit $\hat{f}_n(x)$ eine gültige Wahrscheinlichkeitsdichte ist und gute Eigenschaften besitzt, muss die Kernfunktion K bestimmte mathematische Bedingungen erfüllen. Diese Anforderungen stellen sicher, dass der Schätzer theoretisch fundiert ist und in der Praxis zu sinnvollen Ergebnissen führt:

1. **Normierung:** $\int_{-\infty}^{\infty} K(x)\,dx = 1$ (garantiert, dass die geschätzte Dichte zu 1 integriert). Diese Bedingung ist notwendig, damit $\hat{f}_n$ als Wahrscheinlichkeitsdichte interpretiert werden kann und die Gesamtwahrscheinlichkeit erhalten bleibt.

2. **Nicht-Negativität:** $K(x) \geq 0$ (damit keine negativen Wahrscheinlichkeiten entstehen). In der Praxis werden manchmal auch sogenannte höhere-Ordnung-Kerne verwendet, die lokal negativ werden können (um den Bias weiter zu reduzieren), allerdings sind diese in der Standardanwendung nicht üblich.

3. **Symmetrie:** Üblicherweise gilt $K(x) = K(-x)$. Daraus folgt $\int xK(x)\,dx = 0$ (Erwartungswert 0). Die Symmetrie stellt sicher, dass der Kern in beide Richtungen gleich gewichtet und somit keine systematische Verschiebung der Schätzung auftritt. Asymmetrische Kerne können in speziellen Anwendungen sinnvoll sein, etwa zur Randkorrektur.

4. **Endliche Varianz:** $\sigma_K^2 = \int x^2 K(x)\,dx < \infty$. Diese Bedingung ist wichtig für die Analyse der asymptotischen Eigenschaften des Schätzers, insbesondere für die Herleitung der optimalen Bandbreite.

5. **Zusätzliche Glattheitseigenschaften:** In vielen theoretischen Untersuchungen wird zusätzlich gefordert, dass K stetig oder sogar differenzierbar ist. Dies überträgt sich auf die Glattheit von $\hat{f}_n$ und erlaubt die Schätzung von Ableitungen der Dichte.

4.3 Wahl des Kerns

Gebräuchliche Kerne sind:

- **Rechteck-Kern (Uniform-Kern):**

$$K(x) = \begin{cases} \frac{1}{2} & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases} \tag{6}$$

  Entspricht dem naiven Rosenblatt-Schätzer. Dieser Kern ist nicht stetig und führt zu unstetig differenzierbaren Dichteschätzungen, wird aber aufgrund seiner Einfachheit und Effizienz gelegentlich verwendet.

- **Gauß-Kern (Normalverteilungskern):**

$$K(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \tag{7}$$

Basiert auf der Standardnormalverteilung und ist glatt und beliebig oft differenzierbar. Der Gauß-Kern hat unbeschränkten Träger, d.h., er gewichtet alle Datenpunkte (wenn auch mit exponentiell abfallendem Gewicht). Dies führt zu sehr glatten Schätzungen, kann aber rechenintensiver sein als Kerne mit kompaktem Träger.

- **Epanechnikov-Kern [Epa69]:**

$$K(x) = \begin{cases} \frac{3}{4}(1 - x^2) & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases} \tag{8}$$

  Parabolisch geformt; dieser Kern ist theoretisch optimal, da er den integrierten mittleren quadratischen Fehler (IMSE) minimiert. Der Epanechnikov-Kern ist stetig, aber nicht differenzierbar an den Rändern $x = \pm 1$. Trotz seiner theoretischen Optimalität sind die praktischen Unterschiede zu anderen gängigen Kernen (wie dem Gauß-Kern) oft vernachlässigbar.
- **Weitere Kerne:** In der Literatur finden sich zahlreiche weitere Kerne, darunter der Dreieckskern, der biquadratische Kern und der Triweight-Kern. Die Wahl des Kerns hat in der Praxis oft einen geringeren Einfluss auf die Qualität der Schätzung als die Wahl der Bandbreite h.

Praktische Empfehlung: In den meisten Anwendungen ist die Wahl des Kerns von untergeordneter Bedeutung. Der Gauß-Kern wird häufig bevorzugt, da er glatt ist und in vielen Softwarepaketen standardmäßig implementiert ist. Entscheidender für die Güte der Schätzung ist die Bandbreitenwahl.

4.4 Statistische Eigenschaften und Bandbreitenwahl

Die Qualität des Schätzers wird maßgeblich durch die Bandbreite h bestimmt, die dabei wesentlich entscheidender ist als die Wahl der Kernform. Zur Analyse betrachten wir den **Mean Squared Error (MSE)** an der Stelle x:

$$\text{MSE}(\hat{f}_n(x)) = \text{Varianz}(\hat{f}_n(x)) + [\text{Bias}(\hat{f}_n(x))]^2 \tag{9}$$

Der MSE quantifiziert die erwartete quadratische Abweichung des Schätzers von der wahren Dichte. Er setzt sich aus zwei Komponenten zusammen: Der Varianz, die die Streuung des Schätzers bei wiederholten Stichproben misst, und dem Bias, der die systematische Verzerrung des Schätzers beschreibt.

Es existiert ein fundamentaler Zielkonflikt (Bias-Variance-Tradeoff):

- **Kleines h:** Führt zu kleiner Verzerrung (Bias), aber großer Varianz. Der Graph wird „zackig“ (Unterglättung). Im Extremfall würde $h \to 0$ dazu führen, dass der Schätzer nur noch von den unmittelbar benachbarten Datenpunkten beeinflusst wird, was zu einer stark verrauschten Schätzung führt.
- **Großes h:** Führt zu kleiner Varianz, aber großem Bias. Wichtige Details der Verteilung werden „weggeglättet“ (Überglättung). Bei sehr großem h nähert sich der Schätzer einer Gleichverteilung an und verliert jegliche Information über die Struktur der wahren Dichte.

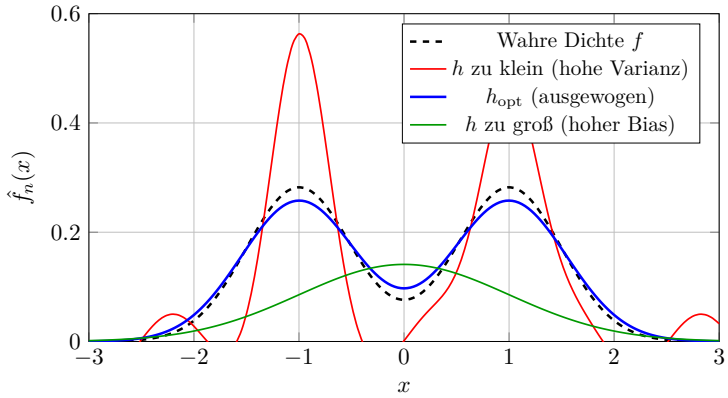

Abbildung 1: Einfluss der Bandbreite h auf die Kerndichteschätzung bei einer bimodalen Verteilung. Zu kleines h führt zu Unterglättung (überangepasst, hohe Varianz), zu großes h zu Überglättung (beide Modes werden verschmiert, hoher Bias).

Asymptotische Analyse: Unter geeigneten Regularitätsbedingungen (insbesondere zweifache Differenzierbarkeit der Dichte f) lässt sich zeigen:

- Der Bias ist von der Ordnung $O(h^2)$ (bei Kernen zweiter Ordnung).
- Die Varianz ist von der Ordnung $O((nh)^{-1})$.
- Der MSE ist damit asymptotisch von der Ordnung $MSE(x) \approx C_1 h^4 + \frac{C_2}{nh}$, wobei C_1 und C_2 von der Dichte f, ihrer zweiten Ableitung und dem Kern abhängen.

Durch Minimierung des asymptotischen MSE bezüglich h erhält man die optimale Bandbreite. Setzen wir

$$\text{MSE}(x) \approx C_1 h^4 + \frac{C_2}{nh}$$

und leiten nach h ab:

$$\begin{aligned}
\frac{d}{dh}\left[C_1 h^4 + \frac{C_2}{nh}\right] = 4C_1 h^3 - \frac{C_2}{nh^2} &\overset{!}{=} 0 \\
\Rightarrow \quad 4C_1 h^3 &= \frac{C_2}{nh^2} \\
\Rightarrow \quad h^5 &= \frac{C_2}{4C_1 n} \\
\Rightarrow \quad h_{\text{opt}} &= \left(\frac{C_2}{4C_1 n}\right)^{1/5} \sim n^{-1/5}
\end{aligned}$$

Dies führt zum minimalen MSE der Ordnung $\text{MSE}_{\text{opt}} \sim n^{-4/5}$, die bestmögliche Konvergenzrate für die Schätzung einer glatten Dichte in einer Dimension.

Eine gängige Faustregel zur Wahl der optimalen Bandbreite (unter Annahme einer Normalverteilung) ist die **Silverman-Regel** [Sil86] (für Gauß-Kerne):

$$h_{\text{opt}} \approx 1.06\, \sigma\, n^{-1/5} \tag{10}$$

Oft wird σ robust durch den Quartilsabstand geschätzt ($\hat{h}_{\text{opt}} \approx 0.79\, Q\, n^{-1/5}$), um Oversmoothing bei Verteilungen mit Ausreißern zu vermeiden. Hier ist $Q = x_{0.75} - x_{0.25}$ der Interquartilsabstand.

Numerisches Beispiel: Bei $n = 100$ Beobachtungen mit geschätzter Standardabweichung $\hat{\sigma} = 1$ ergibt sich:

$$h_{\text{opt}} \approx 1.06 \cdot 1 \cdot 100^{-1/5} = 1.06 \cdot 100^{-0.2} \approx 1.06 \cdot 0.398 \approx 0.42$$

Bei $n = 1000$ wäre $h_{\text{opt}} \approx 1.06 \cdot 1000^{-0.2} \approx 0.27$, was die langsame Konvergenzrate $n^{-1/5}$ verdeutlicht.

Weitere Methoden zur Bandbreitenwahl:

- **Kreuzvalidierung (Cross-Validation):** Wählt h durch Minimierung einer Schätzung des integrierten MSE. Diese Methode ist datengetrieben und verzichtet auf Normalverteilungsannahmen, ist aber rechenintensiver.
- **Plug-In-Methoden:** Schätzen die unbekannten Größen in der asymptotischen MSE-Formel aus den Daten und berechnen daraus ein optimales h.

In der Praxis empfiehlt es sich oft, verschiedene Bandbreiten auszuprobieren und die Sensitivität der Ergebnisse zu überprüfen, insbesondere wenn wichtige Entscheidungen auf Basis der Dichteschätzung getroffen werden sollen.

4.5 KDE als Faltung

Die Kerndichteschätzung lässt sich elegant durch die mathematische Operation der Faltung (Konvolution) interpretieren. Diese Sichtweise liefert tiefere Einsichten in die theoretischen Eigenschaften des Schätzers, insbesondere bezüglich des Bias.

Der Kerndichteschätzer kann als Faltung des skalierten Kerns K_h mit dem empirischen Maß F_n dargestellt werden:

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \quad \text{wobei} \quad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right) \tag{11}$$

Hierbei ist K_h die skalierte Version des Kerns, die die Bandbreite h berücksichtigt. Die Integration über das empirische Maß F_n entspricht der gewichteten Summation über die Datenpunkte, die wir bereits kennen.

Erwartungswert und Bias: Bildet man den Erwartungswert des Schätzers, so erhält man:

$$\mathbb{E}[\hat{f}_n(x)] = (K_h * f)(x) = \int K_h(x-y) f(y)\, dy \tag{12}$$

Diese Darstellung zeigt, dass der Erwartungswert des Schätzers eine *geglättete* Version der wahren Dichte f ist. Der Bias entsteht also durch den **Glättungsfehler der Faltung**: Die Faltung mit dem Kern K_h „verschmiert“ die wahre Dichte, wodurch feine Strukturen verloren gehen können.

Interpretation des Bias:

- Je breiter der Kern (größeres h), desto stärker die Glättung und desto größer der Bias.
- Die Faltung bewirkt, dass scharfe Spitzen der Dichte f abgeflacht werden.

- In der Fourier-Analysis entspricht die Faltung einer Multiplikation im Frequenzbereich, wobei hohe Frequenzen (feine Details) gedämpft werden.

Diese Faltungsperspektive ist nicht nur mathematisch elegant, sondern auch praktisch nützlich: Sie erklärt, warum die Wahl der Bandbreite h so kritisch ist und wie der Bias asymptotisch von h und den Glattheitseigenschaften von f abhängt.

5 Nichtparametrische Regression

Das Konzept der Kernschätzung lässt sich auf die Regressionsanalyse übertragen. Hier verlassen wir die Dichteschätzung und betrachten den Zusammenhang zwischen zwei Variablen X und Y: $Y = m(X)+\epsilon$. Gegeben sind Beobachtungen (X_i, Y_i) für $i = 1, \ldots, n$, und gesucht ist die unbekannte Regressionsfunktion $m(x) = \mathbb{E}(Y|X = x)$.

Während in der parametrischen Regression (z. B. lineare Regression) eine spezifische funktionale Form für $m(x)$ angenommen wird (etwa $m(x) = \alpha+\beta x$), verzichtet die nichtparametrische Regression auf solche Annahmen. Dies erlaubt es, komplexe, nichtlineare Zusammenhänge zu modellieren, ohne vorab eine funktionale Form festzulegen.

5.1 Nadaraya-Watson-Schätzer (Allgemeine Regression)

Wenn wir keine Formel für $m(x)$ kennen, schätzen wir den Wert als gewichteten Mittelwert der umliegenden Y-Werte. Der **Nadaraya-Watson-Schätzer** [Nad64; Wat64] ist definiert als:

$$\hat{m}_{\mathrm{NW}}(x) = \frac{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right) Y_i}{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right)} \tag{13}$$

Datenpunkte X_i, die nahe an x liegen, erhalten durch den Kern K ein hohes Gewicht. Hierbei erhalten Y-Werte, deren X-Koordinaten nahe bei x liegen, ein höheres Gewicht. Die Gewichte sind proportional zu $K\left(\frac{x-X_i}{h}\right)$ und werden durch den Nenner normiert.

Interpretation: Der Schätzer ist im Wesentlichen ein lokaler gewichteter Mittelwert: An jedem Punkt x wird die Regressionsfunktion durch den gewichteten Durchschnitt der beobachteten Y-Werte in der Nähe von x approximiert. Je größer die Bandbreite h, desto mehr Datenpunkte tragen zur Schätzung bei, was zu einer glatteren Kurve führt.

Eigenschaften und Probleme:

- **Bias an den Rändern:** Der Nadaraya-Watson-Schätzer kann an den Rändern des Datenbereichs zu starken Verzerrungen führen, da dort weniger Datenpunkte zur Mittelung zur Verfügung stehen.
- **Design-Adaptation:** Der Schätzer passt sich automatisch an die Dichte der X-Werte an. In Bereichen mit vielen Beobachtungen wird die Schätzung präziser, in dünner besetzten Bereichen variabler.
- **Bandbreitenwahl:** Wie bei der Kerndichteschätzung ist die Wahl von h entscheidend. Zu kleine Werte führen zu überangepassten, „zackigen“ Schätzungen, zu große Werte glätten wichtige Strukturen weg.

Verallgemeinerungen: Lokale Polynomschätzer (Local Polynomial Regression) sind eine Weiterentwicklung, die viele Probleme des Nadaraya-Watson-Schätzers – insbesondere den Randbias – behebt. Dabei wird nicht nur der lokale Mittelwert, sondern ein lokales Polynom (meist linear oder quadratisch) angepasst.

5.2 Robuste Lineare Regression (Theil-Schätzer)

Selbst wenn wir einen linearen Trend ($Y = \alpha + \beta X$) vermuten, ist die klassische Methode der kleinsten Quadrate (OLS) anfällig für Ausreißer. Falls ein linearer Zusammenhang angenommen wird, aber die Daten Ausreißer enthalten, bieten sich robuste Alternativen an. Ein einzelner extremer Datenpunkt kann die OLS-Schätzung erheblich verzerren, während robuste Verfahren solche Einflüsse abschwächen.

1. **Theil-Methode I [The50]:** Man teilt die Daten in zwei Hälften und berechnet Steigungen zwischen Paaren $(i, i + n/2)$. Der Schätzer ist der Median dieser Steigungen. Diese Methode ist einfach zu implementieren, nutzt aber nicht die gesamte verfügbare Information aus den Daten.

2. **Theil-Sen-Schätzer (Methode II) [The50; Sen68]:** Dies ist die präzisere und noch robustere Variante. Man berechnet die Steigung zwischen **allen** möglichen Paaren $i < j$:
$$H_{ij} = \frac{Y_j - Y_i}{X_j - X_i} \tag{14}$$
Der Schätzer für den Anstieg β ist der **Median** all dieser Steigungen (H_{ij}). Das macht ihn extrem robust und besonders widerstandsfähig gegen Ausreißer. Der Theil-Sen-Schätzer hat einen *Breakdown Point* von etwa 29,3 %, d. h. er kann bis zu diesem Anteil an Ausreißern tolerieren [Sen68]. Dies macht ihn zu einem der robustesten verfügbaren Regressionsschätzer.

   Eigenschaften:
   - Der Theil-Sen-Schätzer ist verteilungsfrei (nonparametrisch) und benötigt keine Normalverteilungsannahme.
   - Er ist äquivariant unter monotonen Transformationen der Variablen.
   - Die Berechnung hat Komplexität $O(n^2)$, kann aber durch spezialisierte Algorithmen effizienter gestaltet werden.
   - Für den Achsenabschnitt α wird häufig der Median der Residuen $Y_i - \hat{\beta} X_i$ verwendet.

3. **Hypothesentests:** Zum Testen von β wird auf rangbasierte Verfahren wie Kendalls τ [Ken38] (Tau) zurückgegriffen, da diese verteilungsfrei sind. Kendalls τ misst die Korrelation zwischen X und Y basierend auf der Anzahl konkordanter und diskordanter Paare und ist ebenfalls robust gegenüber Ausreißern.

4. **Vergleich mit OLS:** Während OLS unter Normalverteilungsannahmen und Abwesenheit von Ausreißern optimal ist (im Sinne der Varianzminimierung unter allen

erwartungstreuen Schätzern), bietet der Theil-Sen-Schätzer eine robuste Alternative, die bei Verletzung dieser Annahmen deutlich bessere Ergebnisse liefert. In Anwendungen mit realen Daten, die häufig Ausreißer oder Messfehlern unterliegen, ist der Theil-Sen-Schätzer oft die bessere Wahl.

6 Zusammenfassung und Fazit

Nichtparametrische Methoden spielen eine zentrale Rolle in der modernen Statistik und Datenanalyse [BT94; Was06]. Sie ermöglichen es, komplexe Datenstrukturen zu analysieren, ohne restriktive Annahmen über die zugrunde liegende Verteilung oder funktionale Form treffen zu müssen.

- **Flexibilität:** Nichtparametrische Methoden (KDE, Kernel-Regression) passen sich den Daten an („let the data speak“) und zwingen ihnen keine Form auf. Sie erfordern weniger Annahmen über die Datenstruktur. Diese Flexibilität macht sie besonders wertvoll in der explorativen Datenanalyse, wo die Verteilungsform a priori unbekannt ist, sowie in Situationen, in denen parametrische Modelle zu restriktiv sind. Für eine vertiefte Behandlung der Theorie und Praxis siehe [Sil86; WJ95; Sco92].
- **Parameter h:** Die Wahl der Bandbreite ist der kritischste Schritt. Es ist ein Kompromiss zwischen Rauschen (zu kleines h) und Informationsverlust (zu großes h). Der Glättungsparameter muss sorgfältig zwischen Bias und Varianz abgewogen werden. Während theoretische Faustregeln (wie die Silverman-Regel) einen guten Ausgangspunkt bieten, empfiehlt sich in der Praxis eine Sensitivitätsanalyse, bei der verschiedene Bandbreiten ausprobiert und verglichen werden.
- **Robustheit:** Verfahren wie der Theil-Sen-Schätzer bieten mächtige Alternativen zur klassischen Regression, besonders wenn Daten Ausreißer enthalten oder nicht normalverteilt sind. Sie ergänzen die nichtparametrischen Dichteschätzer, indem sie unempfindlich gegenüber Ausreißern sind. Diese Kombination aus Flexibilität (durch den Verzicht auf parametrische Annahmen) und Robustheit (durch die Verwendung von Medianen statt Mittelwerten) macht sie besonders geeignet für reale Datensätze.
- **Praktische Anwendungen:** Nichtparametrische Methoden finden breite Anwendung in zahlreichen Bereichen:
  - In der *explorativen Datenanalyse* zur Visualisierung und ersten Charakterisierung von Verteilungen.
  - In der *Bildverarbeitung* zur Glättung und Rauschunterdrückung.
  - In der *Ökonometrie* zur Schätzung nichtlinearer Beziehungen ohne vorab spezifizierte funktionale Form.
  - In der *Biometrie* zur Analyse von Überlebenszeitdaten und zur robusten Trendschätzung.
- **Grenzen und Herausforderungen:** Trotz ihrer Vorteile haben nichtparametrische Methoden auch Einschränkungen:
  - Sie benötigen typischerweise größere Stichprobenumfänge als parametrische Methoden, um vergleichbare Genauigkeit zu erreichen.
  - In höheren Dimensionen leiden sie unter dem sogenannten „Fluch der Dimensio-

nalität“: Die Anzahl der benötigten Beobachtungen wächst exponentiell mit der Dimension.
  - Die Interpretation ist oft weniger direkt als bei parametrischen Modellen (z. B. lässt sich bei einer linearen Regression der Effekt einer Variablenänderung direkt aus dem Koeffizienten ablesen).
- **Ausblick:** Moderne Entwicklungen in der nichtparametrischen Statistik umfassen adaptive Bandbreitenwahl, multivariante Kerndichteschätzung, sowie Kombinationen mit maschinellem Lernen. Insbesondere die Verbindung zu neuronalen Netzen und anderen flexiblen Lernverfahren eröffnet neue Perspektiven für die Analyse komplexer Datenstrukturen.

Nichtparametrische Methoden sind damit ein unverzichtbares Werkzeug der modernen explorativen Datenanalyse und robusten Statistik. Sie bilden eine wichtige Brücke zwischen klassischen statistischen Verfahren und modernen datengetriebenen Ansätzen des maschinellen Lernens. Ihre Fähigkeit, sich flexibel an die Daten anzupassen, ohne starke Vorannahmen zu treffen, macht sie zu einem fundamentalen Bestandteil des statistischen Werkzeugkastens.

Literatur

[BT94] Herbert Büning und Götz Trenkler. *Nichtparametrische statistische Methoden*. Berlin, Boston: De Gruyter, 1994. ISBN: 9783110902990. DOI: doi:10.1515/9783110902990. URL: https://doi.org/10.1515/9783110902990.

[Epa69] V. A. Epanechnikov. „Non-Parametric Estimation of a Multivariate Probability Density“. In: *Theory of Probability & Its Applications* 14.1 (1969), S. 153–158.

[FD81] David Freedman und Persi Diaconis. „On the Histogram as a Density Estimator: L2 Theory“. In: *Zeitschrift für Wahrscheinlichkeitstheorie und Verwandte Gebiete* 57.4 (1981), S. 453–476.

[Ken38] Maurice G. Kendall. „A New Measure of Rank Correlation“. In: *Biometrika* 30.1/2 (1938), S. 81–93.

[Nad64] E. A. Nadaraya. „On Estimating Regression“. In: *Theory of Probability & Its Applications* 9.1 (1964), S. 141–142.

[Par62] Emanuel Parzen. „On Estimation of a Probability Density Function and Mode“. In: *The Annals of Mathematical Statistics* 33.3 (1962), S. 1065–1076.

[Ros56] Murray Rosenblatt. „Remarks on Some Nonparametric Estimates of a Density Function“. In: *The Annals of Mathematical Statistics* 27.3 (1956), S. 832–837.

[Sco79] David W. Scott. „On Optimal and Data-Based Histograms“. In: *Biometrika* 66.3 (1979), S. 605–610.

[Sco92] David W. Scott. *Multivariate Density Estimation: Theory, Practice, and Visualization*. New York: John Wiley & Sons, 1992. ISBN: 978-0471547709.

[Sen68] Pranab Kumar Sen. „Estimates of the Regression Coefficient Based on Kendall's Tau“. In: *Journal of the American Statistical Association* 63.324 (1968), S. 1379–1389.

[Sil86] Bernard W. Silverman. *Density Estimation for Statistics and Data Analysis*. Monographs on Statistics and Applied Probability. London: Chapman und Hall, 1986. ISBN: 978-0412246203.

[The50] Henri Theil. „A Rank-Invariant Method of Linear and Polynomial Regression Analysis“. In: *Proceedings of the Koninklijke Nederlandse Akademie van Wetenschappen* 53 (1950), S. 386–392, 521–525, 1397–1412.

[Was06] Larry Wasserman. *All of Nonparametric Statistics*. Springer Texts in Statistics. New York: Springer, 2006. ISBN: 978-0387251455.

[Wat64] Geoffrey S. Watson. „Smooth Regression Analysis“. In: *Sankhyā: The Indian Journal of Statistics, Series A* 26.4 (1964), S. 359–372.

[WJ95] M. P. Wand und M. C. Jones. *Kernel Smoothing*. Monographs on Statistics and Applied Probability. London: Chapman und Hall, 1995. ISBN: 978-0412552700.