Einführung in die Kerndichteschätzung und nichtparametrische Regression

Yavuzâlp Dal

Seminar: Angewandte Statistik

Inhaltsverzeichnis

1 Einleitung und Motivation **2**

2 Der Schätzer von Rosenblatt **2**

3 Das Histogramm **2**

4 Kerndichteschätzung (KDE) **3**
4.1 Definition 3
4.2 Intuitive Funktionsweise 3
4.3 Anforderungen an den Kern 3
4.4 Statistische Eigenschaften und Bandbreitenwahl 4

5 Nichtparametrische Regression **5**

6 Robuste Lineare Regression **5**
6.1 Theil-Schätzer (Methode I) 5
6.2 Theil-Sen-Schätzer (Methode II) 5

7 Fazit **5**

1 Einleitung und Motivation

Die Analyse von Verteilungen ist ein zentraler Bestandteil der Statistik. In der klassischen *parametrischen* Statistik wird häufig angenommen, dass die zugrundeliegende Verteilung einer bekannten Familie angehört, beispielsweise der Normalverteilung. Das Ziel beschränkt sich dort darauf, wenige Parameter wie den Erwartungswert μ oder die Varianz σ^2 zu schätzen.

Dieser Ansatz ist jedoch problematisch, wenn die wahre Verteilung unbekannt ist oder nicht den theoretischen Annahmen entspricht (z. B. bei Schiefe oder Multimodalität). Die *nichtparametrische Dichteschätzung* verzichtet auf die Zugehörigkeit zu einer starren parametrischen Familie. Stattdessen wird lediglich angenommen, dass die Dichte f gewisse Glattheitseigenschaften, wie etwa Stetigkeit oder Differenzierbarkeit, erfüllt. Ziel ist es, eine Annäherung an den Wert $f(x)$ allein aus den Daten zu gewinnen ("Let the data speak").

2 Der Schätzer von Rosenblatt

Historisch betrachtet bildet der Ansatz von Rosenblatt (1956) das Fundament moderner Dichteschätzer. Er motiviert sich aus dem fundamentalen Zusammenhang zwischen der Dichtefunktion f und der Verteilungsfunktion F, wobei gilt: $F'(x) = f(x)$ (sofern F differenzierbar ist).

Der Differentialquotient lässt sich durch den Differenzenquotienten annähern:

$$f(x) \approx \frac{F(x+h) - F(x-h)}{2h}. \tag{1}$$

Ersetzt man die unbekannte Verteilungsfunktion F durch die empirische Verteilungsfunktion F_n, erhält man den **Rosenblatt-Schätzer**:

$$f_n(x) = \frac{F_n(x+h) - F_n(x-h)}{2h}. \tag{2}$$

Intuitiv zählt dieser Schätzer die relative Häufigkeit der Stichprobenwerte, die in das Intervall $(x-h, x+h]$ fallen, und normiert diese durch die Breite $2h$. Er entspricht einem „gleitenden Histogramm“ und ist, wie wir später sehen werden, ein Spezialfall der Kernschätzung mit einem Rechteck-Kern.

3 Das Histogramm

Das Histogramm ist die älteste und bekannteste Methode der Dichteschätzung. Der Datenraum wird hierbei in disjunkte Intervalle (Klassen/Bins) B_k der Breite h unterteilt.

Der Histogrammschätzer $\hat{f}_H(x)$ ist definiert als:

$$\hat{f}H(x) = \frac{1}{nh} \sum k n_k I_{B_k}(x), \tag{3}$$

wobei n_k die Anzahl der Beobachtungen im k-ten Intervall ist und I_{B_k} die Indikatorfunktion darstellt.

Trotz seiner Einfachheit weist das Histogramm gravierende Nachteile auf:

- **Unstetigkeit:** Die geschätzte Dichte ist eine Treppenfunktion, auch wenn die wahre Dichte f stetig oder differenzierbar ist.
- **Subjektivität:** Das Ergebnis hängt stark von der Wahl des Ursprungs x_0 (Gitterverschiebung) und der Bandbreite h ab.

Um diese Mängel zu beheben, wurden die Kernschätzer entwickelt, die eine glattere und flexiblere Anpassung ermöglichen.

4 Kerndichteschätzung (KDE)

4.1 Definition

Die Kerndichteschätzung (Kernel Density Estimation) verallgemeinert den Rosenblatt-Ansatz. Anstatt Beobachtungen nur in starren Boxen zu zählen, gewichtet man sie mittels einer glatten Funktion K, dem sogenannten Kern.

Der Kerndichteschätzer ist definiert als:

$$\hat{f}n(x) = \frac{1}{nh} \sum i = 1^n K\left(\frac{x - X_i}{h}\right). \tag{4}$$

Hierbei ist $h > 0$ der Glättungsparameter (Bandbreite) und n der Stichprobenumfang.

4.2 Intuitive Funktionsweise

Das Vorgehen lässt sich anschaulich als „Summe von Hügeln“ beschreiben:

1. Über jedem Datenpunkt X_i wird eine Kernfunktion (z. B. eine Glockenkurve) platziert.
2. Die Breite dieser Kerne wird durch h gesteuert.
3. An einer Stelle x werden die Werte aller dieser lokalen Kerne aufsummiert und durch nh geteilt, damit die Gesamtfläche unter der Kurve genau 1 ergibt.

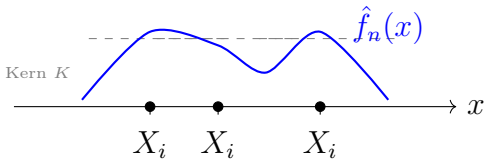

4.3 Anforderungen an den Kern

Damit $\hat{f}_n(x)$ eine gültige Wahrscheinlichkeitsdichte ist und gute Eigenschaften besitzt, muss die Funktion K bestimmte mathematische Bedingungen erfüllen:

1. **Normierung:** $\int_{-\infty}^{\infty} K(x)dx = 1$. Dies garantiert, dass die geschätzte Dichte zu 1 integriert.

2. **Nicht-Negativität:** $K(x) \geq 0$, damit keine negativen Wahrscheinlichkeiten entstehen.

3. **Symmetrie:** Üblicherweise gilt $K(x) = K(-x)$. Daraus folgt $\int xK(x)dx = 0$ (Erwartungswert 0).

4. **Endliche Varianz:** $\sigma_K^2 = \int x^2 K(x)dx < \infty$.

Gebräuchliche Kerne sind:

- **Gauß-Kern:** Basiert auf der Normalverteilung, liefert sehr glatte (differenzierbare) Schätzungen.
- **Epanechnikov-Kern:** $K(x) = \frac{3}{4}(1 - x^2)$ für $|x| \leq 1$. Dieser Kern minimiert asymptotisch den mittleren quadratischen Fehler (MSE).
- **Rechteck-Kern:** Führt auf den Rosenblatt-Schätzer zurück.

4.4 Statistische Eigenschaften und Bandbreitenwahl

Die Qualität des Schätzers wird maßgeblich durch die Bandbreite h bestimmt. Wir betrachten dazu den **Mean Squared Error (MSE)** an der Stelle x:

$$MSE(\hat{f}_n(x)) = \text{Varianz}(\hat{f}_n(x)) + [\text{Bias}(\hat{f}_n(x))]^2. \tag{5}$$

Es existiert ein fundamentaler Zielkonflikt (Bias-Variance-Tradeoff):

- **Kleines h:** Führt zu kleiner Verzerrung (Bias), aber großer Varianz. Der Graph wird „zackig“ (Unterglättung).
- **Großes h:** Führt zu kleiner Varianz, aber großem Bias. Wichtige Details der Verteilung werden „weggeglättet“ (Überglättung).

Konsistenz: Der Schätzer ist konsistent im quadratischen Mittel ($MSE \to 0$), wenn für den Stichprobenumfang $n \to \infty$ gilt:

- $h \to 0$ (um den Bias zu eliminieren).
- $nh \to \infty$ (um die Varianz zu eliminieren).

Eine gängige Faustregel zur Wahl der optimalen Bandbreite (unter Annahme einer Normalverteilung) ist die **Silverman-Regel**:

$$h_{opt} \approx 1.06\, \sigma\, n^{-1/5}. \tag{6}$$

Dabei wird σ oft durch die Standardabweichung s oder den Interquartilsabstand geschätzt.

5 Nichtparametrische Regression

Das Konzept der Kernschätzung lässt sich auf die Regressionsanalyse übertragen. Gegeben sind Beobachtungen (X_i, Y_i) und das Modell $Y_i = m(X_i) + \epsilon_i$. Gesucht ist die unbekannte Funktion $m(x) = E(Y|X = x)$.

Der **Watson-Nadaraya-Schätzer** löst dies durch einen gewichteten Mittelwert:

$$\hat{m}WN(x) = \frac{\sum i = 1^n K\left(\frac{x-X_i}{h}\right) Y_i}{\sum_{i=1}^n K\left(\frac{x-X_i}{h}\right)}. \tag{7}$$

Hierbei erhalten Y-Werte, deren X-Koordinaten nahe bei x liegen, ein höheres Gewicht.

6 Robuste Lineare Regression

Falls ein linearer Zusammenhang $Y = \gamma + \beta X$ angenommen wird, aber die Daten Ausreißer enthalten (wodurch die Methode der kleinsten Quadrate versagt), bieten sich robuste Verfahren an.

6.1 Theil-Schätzer (Methode I)

Hierbei werden Paare von Beobachtungen gebildet, z. B. (X_i, Y_i) und $(X_{i+n/2}, Y_{i+n/2})$. Man berechnet die Steigungen dieser Paare und wählt deren Median als Schätzer für β.

6.2 Theil-Sen-Schätzer (Methode II)

Dieser Ansatz ist noch robuster. Man berechnet die Steigungen H_{ij} für **alle** Paare $i < j$:

$$H_{ij} = \frac{Y_j - Y_i}{X_j - X_i}. \tag{8}$$

Der Schätzer $\hat{\beta}$ ist der Median aller dieser Steigungen. Dieses Verfahren ist besonders widerstandsfähig gegen Ausreißer.

7 Fazit

Nichtparametrische Methoden wie die Kerndichteschätzung und die Kernregression bieten eine flexible Alternative zu parametrischen Modellen. Sie erfordern weniger Annahmen über die Datenstruktur. Der kritische Punkt ist die Wahl des Glättungsparameters h, der sorgfältig zwischen Bias und Varianz abgewogen werden muss. Robuste Regressionsverfahren (Theil) ergänzen dies, indem sie unempfindlich gegenüber Ausreißern sind.