Einführung in die Kerndichteschätzung

Yavuzâlp Dal

Stand: 14. Dezember 2025

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Parametrische vs. Nichtparametrische Dichteschätzung (Übersicht)

Parametrisch

- Annahme: Verteilung ist bekannt!
- Wenige Parameter (μ, σ^2)
- Schätzung durch Parameterschätzer wie bspw. Maximum-Likelihood

Parametrische vs. Nichtparametrische Dichteschätzung (Übersicht)

Parametrisch

- Annahme: Verteilung ist bekannt!
- Wenige Parameter (μ, σ^2)
- Schätzung durch Parameterschätzer wie bspw. Maximum-Likelihood

Nichtparametrisch (KDE)

- Keine feste Form; die Zufallsvariable X muss aber stetig sein, die Dichte f eine "glatte" Funktion
- Schätzung: Kern (wie bspw. Epanechnikov) sowie Bandbreite h
- Erfolgt mittels des Kerndichteschätzers

Modellannahme vs. Datengetrieben $\longrightarrow$

Einfachheit vs. Flexibilität $\longrightarrow$

Einleitung & Motivation

Warum nichtparametrisch? [BT94]

- Klassische parametrische Verfahren (z. B. unter Annahme einer Normalverteilung) sind oft zu starr.
- Bei unbekannter Verteilung bietet die nichtparametrische Schätzung oft bessere Einblicke in die Datenstruktur.

Einleitung & Motivation (Fortsetzung)

Zielsetzung:

- Annäherung an den Wert $f(x)$ an einer Stelle x, ohne eine spezifische parametrische Familie vorauszusetzen.

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Der Rosenblatt-Schätzer (Die theoretische Basis)

- **Idee:** Da $f(x) = F'(x)$, nutzt man den Differenzenquotienten der empirischen Verteilungsfunktion F_n.

Der Rosenblatt-Schätzer (Formel)

- **Der Schätzer:**

$$f_n(x) = \frac{F_n(x+h) - F_n(x-h)}{2h} \tag{1}$$

Der Rosenblatt-Schätzer (Konsistenz)

- **Konsistenz:** Damit der Schätzer gegen die wahre Dichte konvergiert, muss für $n \to \infty$ gelten:
  - Die Bandbreite $h \to 0$ (Bias reduzieren).
  - $nh \to \infty$ (Varianz reduzieren).

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Das Histogramm (Der Klassiker)

- **Funktionsweise:** Zerlegung des Datenraums in Boxen (Bins) der Breite h. Die Höhe der Box entspricht der relativen Häufigkeit $\frac{n_k}{n}$ normiert durch h.

Das Histogramm (Probleme)

- **Probleme:**
  - Unstetigkeit: Die geschätzte Dichte ist eine Treppenfunktion.
  - Subjektivität: Abhängig von x_0 und h.

Das Histogramm (Optimale Bandbreite)

- **Optimale Bandbreite (h):**
  - Scott: $h \approx 3.49sn^{-1/3}$
  - Freedman-Diaconis: $h^* = 2(x_{0.75} - x_{0.25})n^{-1/3}$

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Kernschätzer (KDE) - Einführung

- **Der Schätzer:**

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right) \tag{2}$$

Kernschätzer (KDE) - Wahl des Kerns

- **Kernwahl:** Der Kern muss zu 1 integrieren ($\int K(x)dx = 1$).
- Gängige Kerne:
  - Rechteck-Kern
  - Gauß-Kern
  - Epanechnikov-Kern

Kernschätzer (KDE) - Bandbreitenwahl

- **Bandbreitenwahl (Silverman's Rule):**

$$h_{opt} \approx 1.06\sigma n^{-1/5} \tag{3}$$

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Nichtparametrische Regression - Einführung

Watson-Nadaraya Schätzer:

$$\hat{m}_{WN}(x) = \frac{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right) Y_i}{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right)} \tag{4}$$

- Schätzung von $m(x)$ als gewichteter Mittelwert der umliegenden Y-Werte.

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Robuste Lineare Regression (Theil-Schätzer) - Einführung

- **Theil-Methode I:** Steigung zwischen Paaren $(i, i + n/2)$, Median als Schätzer.
- **Theil-Sen-Schätzer (Methode II):** Median der Steigungen zwischen allen Paaren $i < j$:

Robuste Lineare Regression (Theil-Schätzer) - Formel

$$H_{ij} = \frac{Y_j - Y_i}{X_j - X_i} \tag{5}$$

- Der Schätzer für den Anstieg β ist der Median dieser Steigungen.

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Zusammenfassung für das Seminar

- **Flexibilität:** Nichtparametrische Methoden passen sich den Daten an.
- **Parameter h:** Kritischer Schritt, Balance zwischen Bias und Varianz.

Zusammenfassung für das Seminar (Fortsetzung)

- **Robustheit:** Verfahren wie der Theil-Sen-Schätzer bieten robuste Alternativen zur klassischen Regression, besonders bei Ausreißern.

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Literaturverzeichnis I

[BT94] Herbert Büning und Götz Trenkler. *Nichtparametrische statistische Methoden*. Berlin, Boston: De Gruyter, 1994. ISBN: 9783110902990. DOI: doi:10.1515/9783110902990. URL: https://doi.org/10.1515/9783110902990.