Kerndichteschätzung und nichtparametrische Regression

Yavuzâlp Dal

Angewandte Statistik

04.03.2026

Inhalt

1. Einleitung & Motivation
2. Rosenblatt-Schätzer
3. Histogramm
4. Kerndichteschätzer
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung

Einleitung & Motivation

Parametrisch

- Verteilung von X ist bekannt (z. B. Normalverteilung)
- Schätzung durch Maximum-Likelihood

Problem:

- Unsichere starke Annahmen

Nichtparametrisch

- Keine parametrische Familie für X vorgegeben
- f zweimal differenzierbar (Regularitätsannahme)
- Schätzung über Kernfunktion K und Bandbreite h

Vorteil:

- Flexibel, datengetrieben

Modellannahme vs. Datengetrieben

$\longleftrightarrow$

Einfachheit vs. Flexibilität

$\longleftrightarrow$

Fallbeispiel: Gewässermessungen der Itter — Messungen

Spektralphotometrische Messungen: Wellenlänge λ vs. gemessene Absorption.

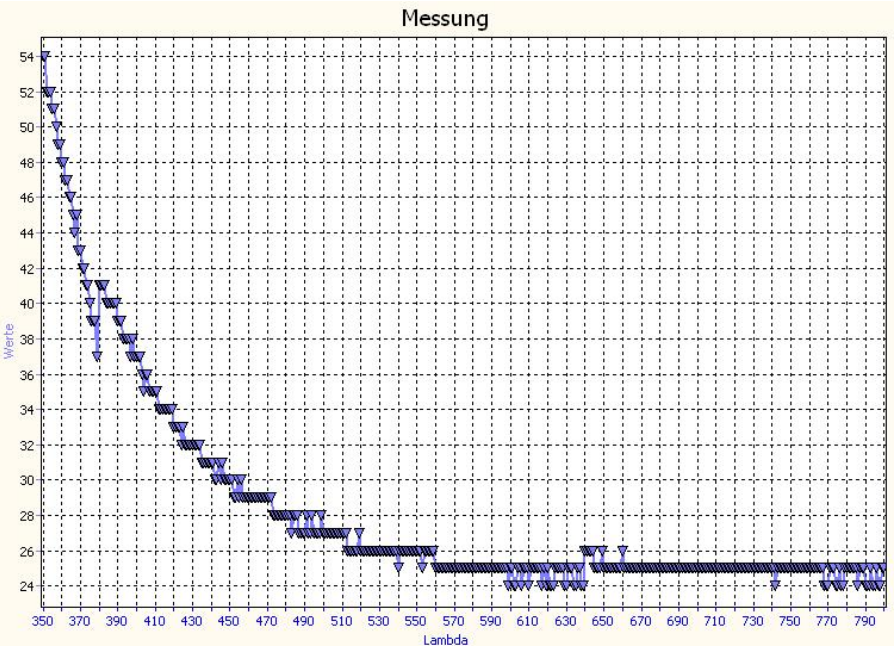

Messung 1: logarithmisch/exponentiell abfallend

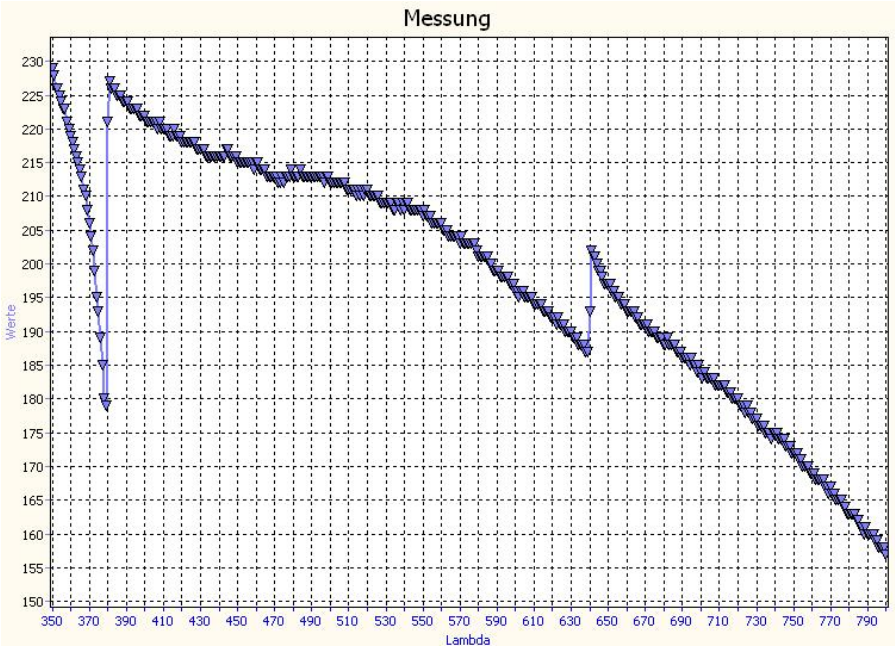

Messung 2: eher linearer Verlauf

Fallbeispiel: Gewässermessungen der Itter — Schlussfolgerung

Fazit:

- Unterschiedliche Messungen desselben Gewässers zeigen grundlegend verschiedene Verteilungsmuster.
- Die beiden starken Sprünge sind darauf zurückzuführen, dass das Spektrometer zeitweise nicht durchgehend messen konnte und neu gestartet werden musste.
  - Die Daten sind daher punktweise verfälscht — man sollte sie nicht zu exakt interpretieren.
- Man darf sich nicht blind auf eine angenommene Verteilung verlassen.
- Deshalb sind nichtparametrische Methoden besonders wertvoll: sie setzen keine bestimmte Verteilungsform voraus.

Wer sich näher interessiert, sei auf [Dal26; Dal21] verwiesen...

Ausgangssituation und Zielsetzung

Gegeben seien unabhängige, identisch verteilte Zufallsvariablen

$$X_1, \ldots, X_n \sim F \quad \text{mit unbekannter Dichte } f.$$

Zielsetzung:

$$\text{Schätze } f(x) \qquad \text{oder} \qquad m(x) = \mathbb{E}(Y|X = x)$$

ohne Annahme einer parametrischen Familie.

Grundprinzip: „Lass die Daten sprechen" – Daten bestimmen die Form der Schätzung.

Inhalt

1. Einleitung & Motivation
2. Rosenblatt-Schätzer
3. Histogramm
4. Kerndichteschätzer
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung

Empirische Verteilungsfunktion

Die empirische Verteilungsfunktion:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{\{X_i \leq x\}}$$

- Konsistenter Schätzer für F.
- Jedoch eine Treppenfunktion.

Wie erhalten wir daraus eine Dichte?

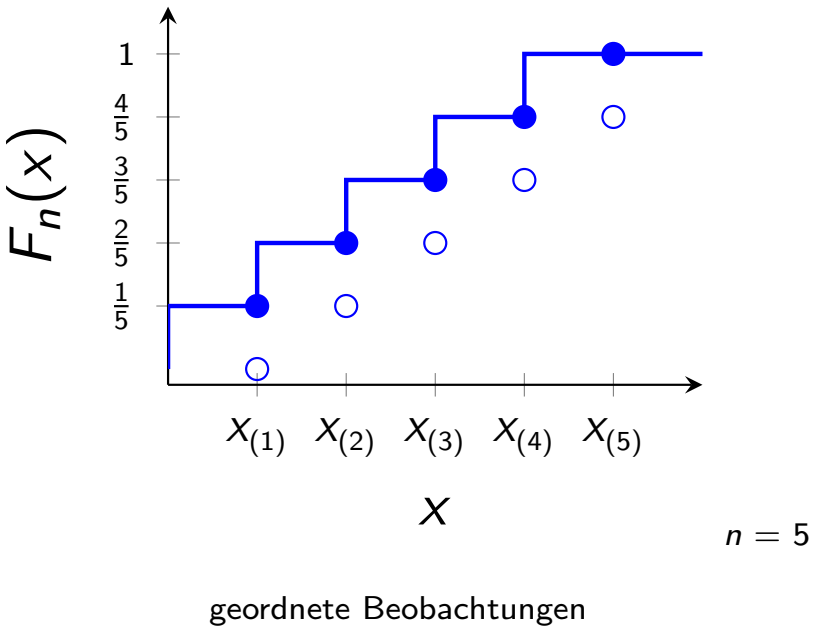

Rosenblatt-Schätzer – Grundidee

Grundprinzip: Da $f(x) = F'(x)$, approximiere die Ableitung durch den symmetrischen Differenzenquotienten:

$$f(x) \approx \frac{F(x+h) - F(x-h)}{2h}.$$

Der Schätzer: Ersetze F durch die empirische Verteilungsfunktion F_n

$$\hat{f}_n(x) = \frac{F_n(x+h) - F_n(x-h)}{2h}.$$

Interpretation:

Die relative Häufigkeit der Beobachtungen in $(x-h, x+h]$, normiert durch $2h$, ergibt ein „gleitendes Histogramm".

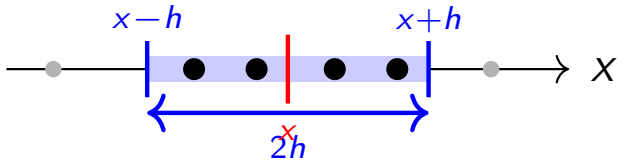

Rosenblatt-Schätzer – Konsistenz

Konsistenzbedingungen: Für $n \to \infty$ muss gelten:

1. $h \to 0$ (Bias reduzieren: Differenzenquotient approximiert Ableitung besser)
2. $nh \to \infty$ (Varianz reduzieren: genügend Daten im Intervall)

Spannungsverhältnis: h darf nicht zu schnell gegen Null konvergieren.

Typische Wahl: $h \approx n^{-\alpha}$ mit $0 < \alpha < 1$

Inhalt

1. Einleitung & Motivation
2. Rosenblatt-Schätzer
3. Histogramm
4. Kerndichteschätzer
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung

Funktionsweise eines Histogramms

- **Funktionsweise:** Zerlegung des Datenraums in Intervalle (Bins) B_k der Breite h. Die Höhe entspricht der relativen Häufigkeit $\frac{n_k}{n}$ normiert durch h, wobei n_k die Anzahl der Beobachtungen in B_k bezeichnet.
- **Formal ist ein Histogramm gegeben durch:**

$$\hat{f}_H(x) = \sum_k \frac{n_k}{nh} \mathbb{1}_{B_k}(x)$$

- Das Histogramm kann damit als Dichteschätzer verwendet werden.

Histogramm – Probleme

- **Unstetigkeit:** Die geschätzte Dichte ist eine Treppenfunktion ohne glatte Übergänge.
- **Subjektivität:** Das Ergebnis hängt von der Wahl des Startpunkts x_0 und der Bandbreite h ab.

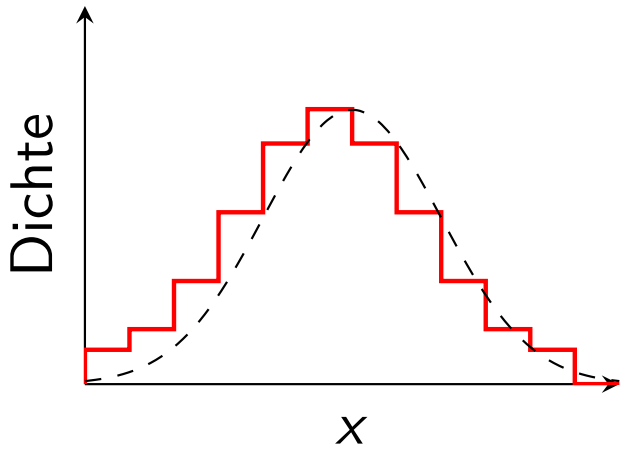

Treppenfunktion (rot) vs. wahre Dichte (schwarz)

Histogramm – Optimale Bandbreite

Faustregeln für die Bandbreitenwahl:

- **Scott-Regel:** $h \approx 3{,}49\,\hat{\sigma}\,n^{-1/3}$ ($\hat{\sigma}$: Stichproben-Standardabweichung)
- **Freedman-Diaconis:** $h^* = 2\,(x_{0,75} - x_{0,25})\,n^{-1/3}$

Kleine Bandbreite (überangepasst)

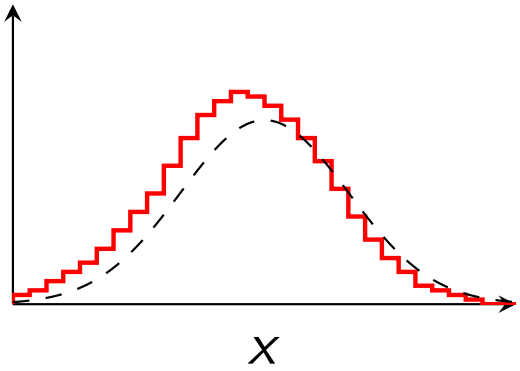

Große Bandbreite (überglättet)

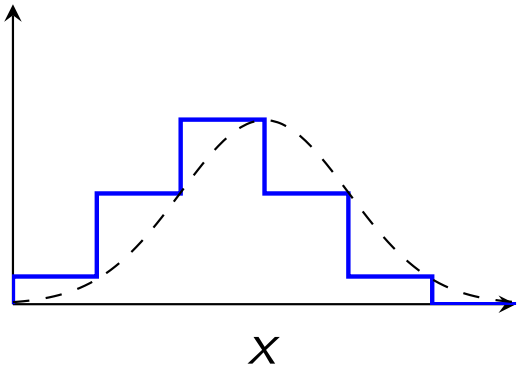

Histogramm vs. Kerndichteschätzung: Visueller Vergleich

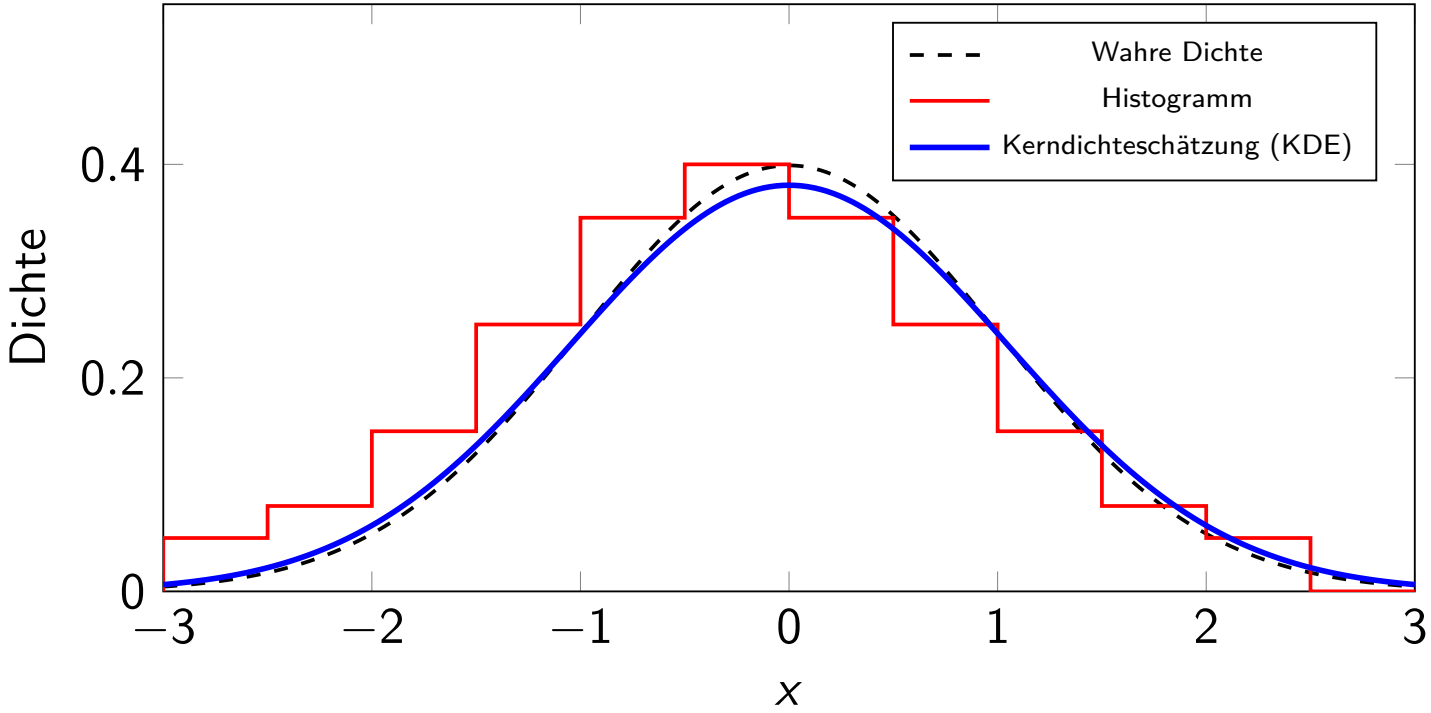

Vorteil KDE: Stetige, glatte Schätzung ohne Sprünge

Inhalt

1. Einleitung & Motivation
2. Rosenblatt-Schätzer
3. Histogramm
4. Kerndichteschätzer
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung

Kerndichteschätzer

- Bei einer Kerndichteschätzung trägt jede Beobachtung zur Schätzung an der Stelle x bei.
- Der Beitrag hängt vom Abstand von X_i zu x ab – nahe Beobachtungen werden stärker gewichtet.
- Statt harter Intervallabgrenzung erfolgt eine stetige Glättung über eine Gewichtungsfunktion (Kernfunktion).

Der Kerndichteschätzer ist gegeben durch:

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right),$$

wobei K eine Kernfunktion und $h > 0$ die Bandbreite ist.

Kerndichteschätzer – Wahl des Kerns

Gängige Kernfunktionen:

- **Rechteck-Kern** (Gleichverteilung) – einfachste Kernfunktion, unstetig
- **Gauß-Kern** – glatt, unbeschränkter Träger
- **Epanechnikov-Kern** – optimal (minimiert IMSE)

Praktische Empfehlung: Gauß-Kern meist ausreichend. Bandbreite h ist entscheidender!

Gängige Kernfunktionen – Formeln

Rechteck-Kern (Gleichverteilung auf $[-1, 1]$):

$$K(x) = \begin{cases} \frac{1}{2} & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases}$$

Gauß-Kern:

$$K(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

Epanechnikov-Kern:

$$K(x) = \begin{cases} \frac{3}{4}(1 - x^2) & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases}$$

Gängige Kernfunktionen – Visualisierung

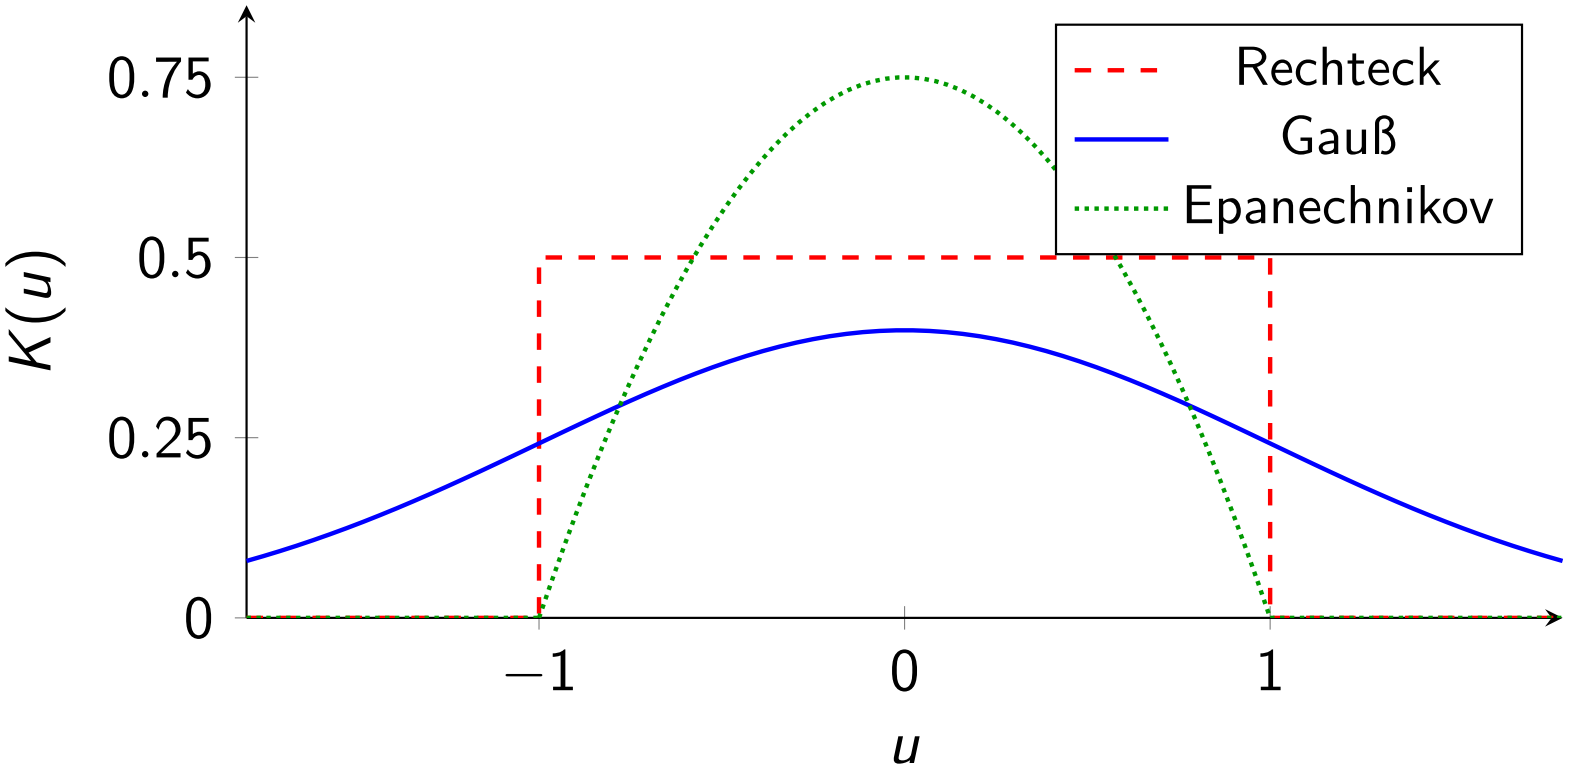

Alle Kerne: $\int K(u)\,du = 1$, symmetrisch, nicht-negativ.

Besonderheit des Epanechnikov-Kerns

- **Theoretisch optimal:** Der Epanechnikov-Kern minimiert den integrierten mittleren quadratischen Fehler

$$\text{IMSE} = \int \text{MSE}(\hat{f}_n(x))\, f(x)\, dx,$$

  der die globale Güte der Schätzung misst.

- Parabolische Form mit kompaktem Träger (effizienter zu berechnen).

- Praktisch kaum Unterschied zu Gauß-Kern – die Bandbreite h ist entscheidender.

Kernfunktion – Mathematische Anforderungen

Ein Kern K muss erfüllen:

1. $K(x) \geq 0$ (verhindert negative Wahrscheinlichkeiten)
2. $\int K(x)\,\mathrm{d}x = 1$ (stellt sicher, dass $\hat{f}_n$ eine gültige Dichte ist)
3. $K(x) = K(-x)$ (vermeidet systematische Verschiebung)
4. $\sigma_K^2 = \int x^2 K(x)\,\mathrm{d}x < \infty$ (notwendig für die Theorie)

Bandbreitenwahl

Silvermans Faustformel:

$$h \approx 1{,}06\,\hat{\sigma}\,n^{-1/5}$$

Datengetriebene Alternativen:

- **Plug-In-Methoden:**
  - Schätzen unbekannte Größen aus Daten.
  - Berechnen optimalen Wert für h aus asymptotischer MSE-Formel.
- **Kreuzvalidierung:**
  - Keine Normalverteilungsannahme nötig.
  - Minimiert geschätzten integrierten MSE.
  - Rechenintensiver.

Kerndichteschätzung – Rolle der Bandbreite

Zentrale Stellgröße der Kerndichteschätzung:

- Kleine Bandbreite: geringe Glättung, hohe Varianz (überangepasst).
- Große Bandbreite: starke Glättung, hoher Bias (überglätten).

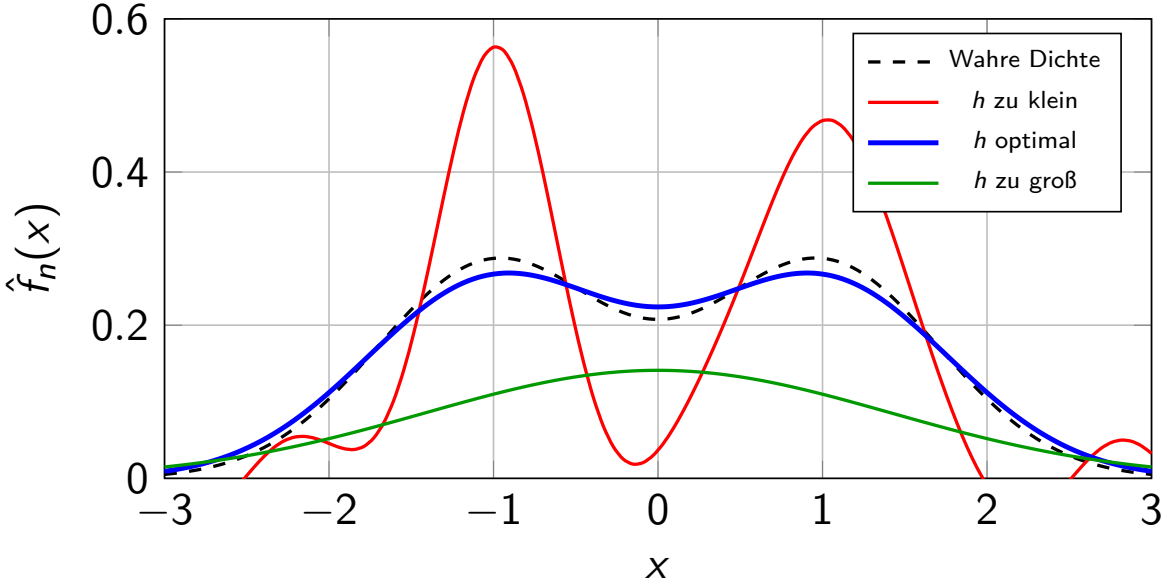

Bimodale Verteilung: h zu klein $\Rightarrow$ überangepasst, h optimal $\Rightarrow$ erfasst beide Modi, h zu groß $\Rightarrow$ verwischt die Struktur

KDE als Faltung

Der Kerndichteschätzer lässt sich als Faltung schreiben:

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \qquad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right).$$

Somit ergibt sich der Erwartungswert als:

$$\mathbb{E}\big[\hat{f}_n(x)\big] = (K_h * f)(x).$$

Da der Erwartungswert eine *geglättete* Version von f ist, folgt:

- Je breiter der Kern (größeres h), desto stärker die Glättung.
- Feine Strukturen werden verwischt.
- Bias = Glättungsfehler der Faltung

O-Notation (angelehnt an [SS21] sowie [Dal23])

Betrachte Funktionen:

- $f : \mathbb{N} \to \mathbb{R}$ (Laufzeit/Fehler)
- $g : \mathbb{N} \to \mathbb{R}$ (Wachstumsordnung)

f **wächst höchstens so schnell wie** g, falls es $c > 0$ und $n_0 \in \mathbb{N}$ gibt mit

$$0 \leq f(n) \leq c \cdot g(n) \quad \forall\, n \geq n_0.$$

Schreibweise: $f(n) \in O(g(n))$

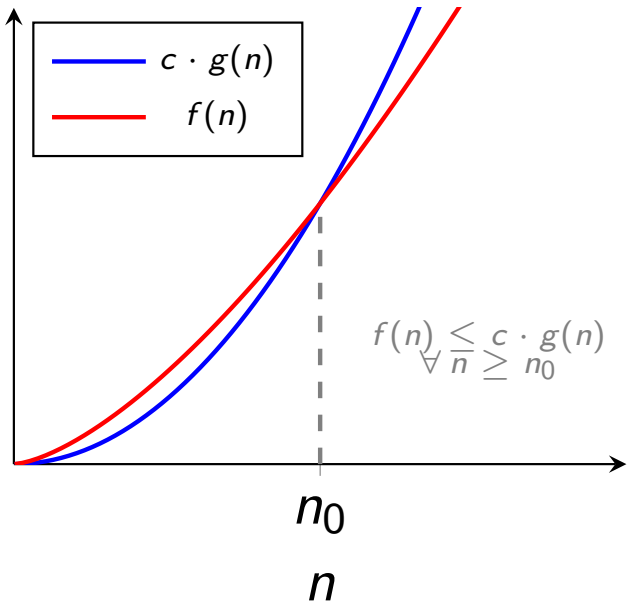

Bias–Varianz-Tradeoff

Unter gewissen Regularitätsannahmen gilt:

$$\mathrm{Bias}(\hat{f}_n(x)) = O(h^2), \qquad \mathrm{Var}(\hat{f}_n(x)) = O\left(\frac{1}{nh}\right)$$

MSE-Zerlegung: Mit $c_1, c_2 > 0$ gilt:

$$\mathrm{MSE}(\hat{f}_n(x)) = \mathrm{Bias}^2(\hat{f}_n(x)) + \mathrm{Var}(\hat{f}_n(x)) \approx c_1 h^4 + \frac{c_2}{nh}$$

Optimierung: Minimiere MSE durch Ableiten nach h:

$$\frac{d}{dh}\left[c_1 h^4 + \frac{c_2}{nh}\right] = 4c_1 h^3 - \frac{c_2}{nh^2} \stackrel{!}{=} 0$$

$\Rightarrow h_{\mathrm{opt}} \sim n^{-1/5}$ und $\mathrm{MSE}_{\mathrm{opt}} \sim n^{-4/5}$

Bias–Varianz-Tradeoff – Visualisierung

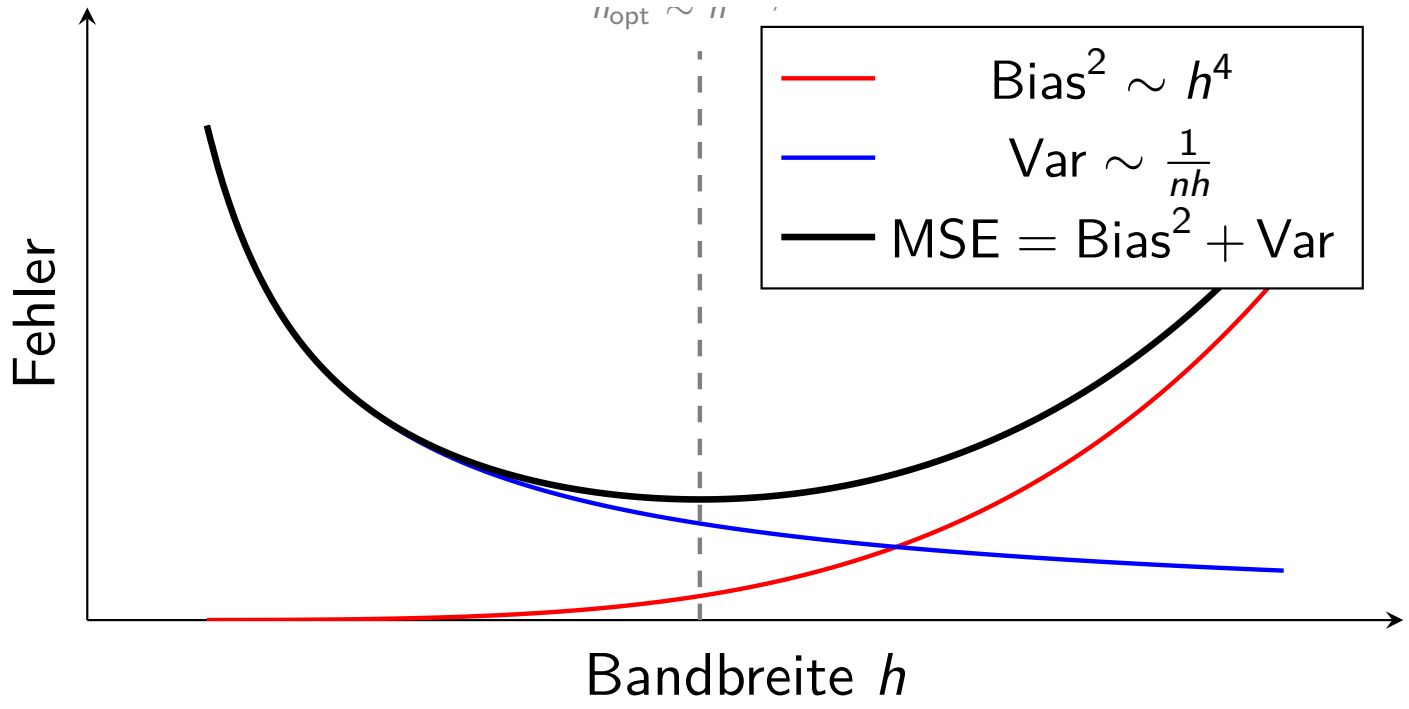

Kleines h: Varianz dominiert | Großes h: Bias dominiert

Bezug zum Rosenblatt-Schätzer

Der Rosenblatt-Schätzer

$$\hat{f}_n(x) = \frac{F_n(x+h) - F_n(x-h)}{2h}$$

kann als Spezialfall des Kerndichteschätzers mit Rechteck-Kern

$$K(u) = \tfrac{1}{2}\,\mathbf{1}_{[-1,1]}(u)$$

aufgefasst werden: Einsetzen in $\frac{1}{nh}\sum_i K(\frac{x-X_i}{h})$ liefert genau $\hat{f}_n$.

Die Kerndichteschätzung verallgemeinert diesen Ansatz und liefert stetige Schätzfunktionen.

Vorteile der Kerndichteschätzung

Vorteile der Kerndichteschätzung:

- Sie liefert eine stetige und glatte Schätzfunktion.
- Sie ist flexibel einsetzbar ohne Annahme einer parametrischen Familie.
- Sie hat gute theoretische Eigenschaften (Konsistenz, bekannte Konvergenzraten).
- Sie bildet die Grundlage für weiterführende nichtparametrische Verfahren.

Inhalt

1. Einleitung & Motivation
2. Rosenblatt-Schätzer
3. Histogramm
4. Kerndichteschätzer
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung

Nichtparametrische Regression – Zielsetzung

Regressionsmodell: Gegeben seien Beobachtungspaare $(X_1, Y_1), \ldots, (X_n, Y_n)$ mit

$$Y_i = m(X_i) + \varepsilon_i, \qquad \mathbb{E}(\varepsilon_i) = 0.$$

Die **Regressionsfunktion** $m(x) = \mathbb{E}(Y \mid X = x)$ beschreibt den mittleren Zusammenhang zwischen X und Y.

Ziel: Schätzung von $m(x)$ ohne Annahme einer konkreten parametrischen Form.

Unterschied zur linearen Regression:

- Kein globales lineares Modell $m(x) = \beta_0 + \beta_1 x$.
- Lokale Anpassung an die Datenstruktur.

Nichtparametrische Regression – Grundidee

Grundidee der lokalen Glättung:

- Beobachtungen mit ähnlichen Werten für X liefern ähnliche Informationen über $m(x)$.
- Beobachtungen in der Nähe von x werden stärker gewichtet.

Umsetzung:

- Die Gewichtung erfolgt über eine Kernfunktion K.
- Die Bandbreite h bestimmt die Größe der lokalen Umgebung.

Nadaraya–Watson-Schätzer

Der **Nadaraya–Watson-Schätzer** schätzt $m(x)$ als gewichteten Mittelwert der Y_i:

$$\hat{m}_{NW}(x) = \frac{\sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right) Y_i}{\sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right)}.$$

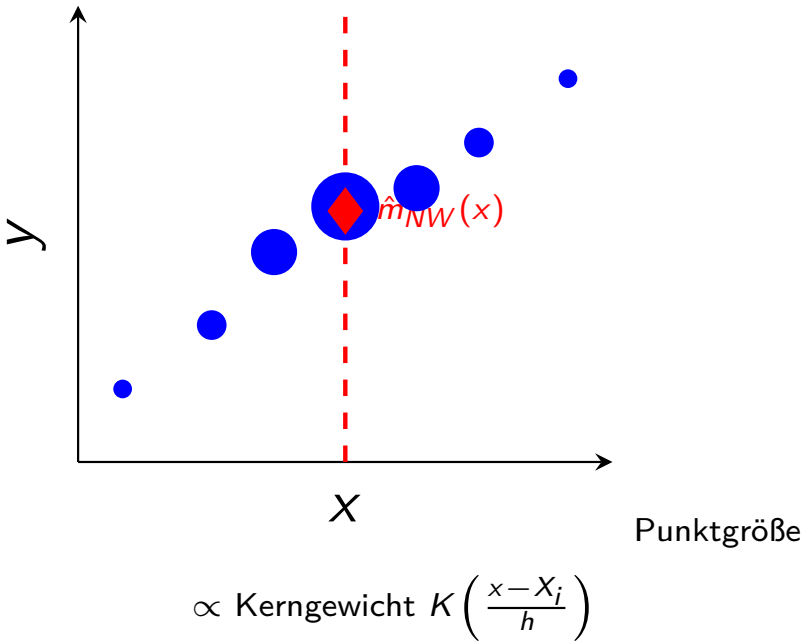

Interpretation:

- Gewichteter Mittelwert der Y_i.
- Nähere X_i erhalten größeres Gewicht.

Nichtparametrische Regression – Rolle der Bandbreite

Einfluss der Bandbreite h:

- Ein kleines h führt zu starker lokaler Anpassung und hoher Varianz.
- Ein großes h führt zu starker Glättung und höherem Bias.
- Es gilt derselbe Bias-Varianz-Tradeoff wie bei der Kerndichteschätzung.

Nichtparametrische Regression – Vorteile und Grenzen

Vorteile der nichtparametrischen Regression:

- Hohe Flexibilität – keine Modellfehlanpassung durch falsche Annahmen.
- Anwendbar auch wenn die funktionale Form von m unbekannt ist.

Grenzen:

- Die Wahl der Bandbreite ist entscheidend für die Schätzgüte.
- Randprobleme: erhöhter Bias an den Grenzen des Datenbereichs.

Bias-Problem an den Datengrenzen

Problem an den Rändern:

- Der Nadaraya-Watson-Schätzer weist starken Bias an den Datengrenzen auf.
- An den Rändern stehen weniger Datenpunkte in der Umgebung zur Verfügung.
- Die asymmetrische Gewichtung führt zur Verzerrung der Schätzung.

Lösungsansatz – Lokale Polynomschätzer:

- Anpassung lokaler Polynome (linear, quadratisch) statt Konstanten.
- Reduzieren den Randbias erheblich.
- Verallgemeinerung des Nadaraya-Watson-Ansatzes.

Bias-Problem an den Datengrenzen – Visualisierung

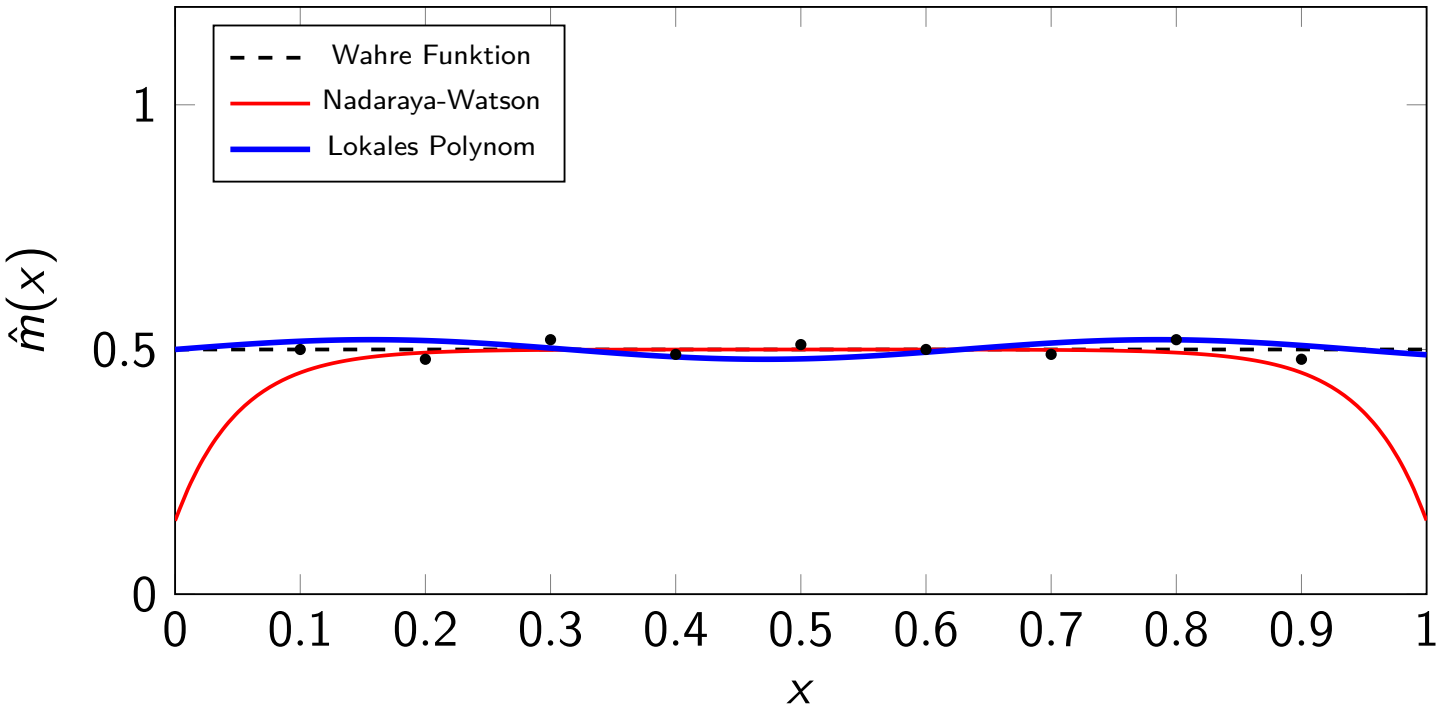

An Rändern: NW-Schätzer verzerrt (nach unten), lokales Polynom korrigiert.

Gemeinsames Prinzip von Kerndichteschätzung und nichtparametrischer Regression (basierend auf [BT94] sowie [Lan04])

Gemeinsames Prinzip:

- Verwendung von Kernfunktionen zur lokalen Gewichtung von Beobachtungen.
- Die Bandbreite h steuert den Grad der Glättung in beiden Verfahren.

Unterschied:

- Kerndichteschätzung: Schätzung der Dichte $f(x)$ von X.
- Nichtparametrische Regression: Schätzung von $m(x) = \mathbb{E}(Y \mid X = x)$.

Strukturelle Sicht – Nadaraya-Watson als Quotient von KDE

Die Regressionsfunktion lässt sich schreiben als:

$$m(x) = \frac{\int y\, f_{XY}(x, y)\, dy}{f_X(x)}.$$

Der Nadaraya-Watson-Schätzer ergibt sich daraus als Quotient von Kerndichteschätzern:

$$\hat{m}(x) = \frac{\hat{r}(x)}{\hat{f}_X(x)}, \qquad \hat{r}(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right) Y_i.$$

Inhalt

1. Einleitung & Motivation
2. Rosenblatt-Schätzer
3. Histogramm
4. Kerndichteschätzer
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung

Kapitel überspringen

Robuste Lineare Regression – Motivation

Problem der klassischen linearen Regression:

- Basiert auf quadratischen Fehlern (Methode der kleinsten Quadrate).
- Einzelne Ausreißer können die Schätzung stark verzerren.

Ziel der robusten linearen Regression:

- Schätzung eines linearen Zusammenhangs zwischen X und Y.
- Geringe Empfindlichkeit gegenüber Ausreißern.

Verbindung zur nichtparametrischen Statistik:

- Wie die Kerndichteschätzung verzichtet auch robuste Regression auf starke Verteilungsannahmen.
- Beide Ansätze streben nach Robustheit durch reduzierte Modellannahmen.

Zentrale Idee der robusten linearen Regression

Zentrale Idee:

- Anstatt eine globale Fehlerfunktion zu minimieren, werden Steigungen zwischen Beobachtungspaaren betrachtet.
- Die Schätzung basiert auf dem Median dieser Steigungen.

Vergleich von Mittelwert und Median:

- Mittelwert: Stark empfindlich gegenüber einzelnen Ausreißern.
- Median: Robust gegenüber extremen Beobachtungen und repräsentiert die zentrale Tendenz der Steigungen.

Theil-Schätzer – Einführung und Formel

Der **Theil-Sen-Schätzer** schätzt β als Median der paarweisen Steigungen H_{ij}:

$$H_{ij} = \frac{Y_j - Y_i}{X_j - X_i}, \quad i < j.$$

Der Schätzer:

$$\hat{\beta} = \text{Median}(H_{ij}).$$

Theil-Methode I: Steigungen nur zwischen Paaren $(i,\ i{+}n/2)$.

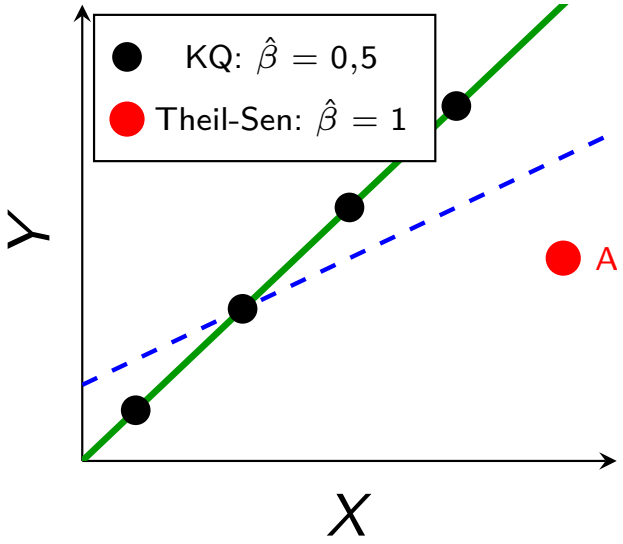

Ein Ausreißer verzerrt KQ stark; Theil-Sen bleibt stabil.

Wichtige Eigenschaften des Theil-Sen-Schätzers

- **Hoher Breakdown-Punkt:** Der Schätzer bleibt stabil, solange weniger als 50 % der Datenpunkte Ausreißer sind. Bei der klassischen linearen Regression reicht ein einziger Ausreißer, um die Schätzung stark zu verzerren.
- **Konsistenz:** Konsistent unter milden Voraussetzungen.
- **Anwendung:** Geeignet bei Datensätzen mit möglichen Ausreißern und in der explorativen Datenanalyse.

Einschränkungen der robusten linearen Regression

Einschränkungen:

- Höherer Rechenaufwand bei großen Stichproben (Theil-Sen: $O(n^2)$ Steigungen).
- Beschränkt auf lineare Zusammenhänge zwischen X und Y.

Abgrenzung zur nichtparametrischen Regression:

- Die nichtparametrische Regression bietet höhere Flexibilität, da sie keine Linearität voraussetzt.
- Dafür ist die Interpretation der nichtparametrischen Regression weniger direkt.

Inhalt

1. Einleitung & Motivation
2. Rosenblatt-Schätzer
3. Histogramm
4. Kerndichteschätzer
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung

Zusammenfassung

- Nichtparametrische Methoden sind lokal und datengetrieben: Sie schätzen $f(x)$ oder $m(x)$ ohne Annahme einer parametrischen Familie.
- Der Kerndichteschätzer lässt sich als Faltung mit dem empirischen Maß auffassen.
- Die Bandbreite h ist die zentrale Stellgröße und bestimmt die Konvergenzrate.
- Die nichtparametrische Regression folgt demselben Prinzip der lokalen Kerngewichtung.
- Robuste Verfahren wie der Theil-Sen-Schätzer bieten Schutz vor Ausreißern bei linearen Modellen.

Fazit und Ausblick

- **Flexibilität:** Nichtparametrische Methoden passen sich den Daten an, ohne eine spezifische funktionale Form vorauszusetzen.
- **Parameter h:** Die Wahl der Bandbreite ist der entscheidende Schritt und erfordert eine Balance zwischen Bias und Varianz.
- **Robustheit:** Verfahren wie der Theil-Sen-Schätzer bieten robuste Alternativen zur klassischen linearen Regression, besonders bei Vorliegen von Ausreißern.

Literaturverzeichnis I

[BT94] Herbert Büning und Götz Trenkler. *Nichtparametrische statistische Methoden*. Berlin, Boston: De Gruyter, 1994. ISBN: 9783110902990. DOI: doi:10.1515/9783110902990. URL: https://doi.org/10.1515/9783110902990.

[Dal21] Yavuzâlp Dal. „Schlechte Wasserqualität der Itter – Ermittlung der Ursachen und Vorschläge für die Verbesserung der Wasserqualität“. In: 1 (Mai 2021).

[Dal23] Yavuzâlp Dal. *Probabilistischer Test für algebraische Operationen*. ResearchGate. Vortrag im Proseminar *Perlen der Linearen Algebra*. 2023. DOI: <DEIN-DOI>. URL: <DEIN-RESEARCHGATE-LINK>.

[Dal26] Yavuzâlp Dal. „Multifaktorielle Belastung der Itter: Chemische, biologische und hydrologische Analyse eines urbanen Gewässers“. Feb. 2026. DOI: 10.13140/RG.2.2.17341.52968.

Literaturverzeichnis II

[Lan04] Stefan Lang. *Skript zur Vorlesung: Computerintensive Verfahren in der Statistik*. Lecture Notes. Ludwigstraße 33, München: Institut für Statistik, Ludwig-Maximilians-Universität München, 15. Jan. 2004. URL: mailto:lang@stat.uni-muenchen.de.

[SS21] Daniel Schmidt und Melanie Schmidt. „Algorithmen und Datenstrukturen“. In: *ILIAS* (2021). Vorlesungsskript, S. 230–242. URL: https://ilias.hhu.de/goto.php?target=file_1552977_download&client_id=UniRZ.