Einführung in die Kerndichteschätzung

Yavuzâlp Dal

Angewandte Statistik

1. März 2026

Inhalt

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Einleitung & Motivation

Parametrisch

- Verteilung von X ist bekannt (z. B. Normalverteilung)
- Wenige Parameter (μ, σ^2)
- Schätzung durch Maximum-Likelihood

Problem:

- Unsichere starke Annahmen

Einleitung & Motivation

Parametrisch

- Verteilung von X ist bekannt (z. B. Normalverteilung)
- Wenige Parameter (μ, σ^2)
- Schätzung durch Maximum-Likelihood

Problem:

- Unsichere starke Annahmen

Nichtparametrisch

- Keine parametrische Familie für X vorgegeben
- Annahmen: X stetig, f glatt (zweimal differenzierbar)
- Schätzung über Kernfunktion K und Bandbreite h

Vorteil:

- Flexibel, datengetrieben

Modellannahme vs. Datengetrieben

$\longleftrightarrow$

Einfachheit vs. Flexibilität

$\longleftrightarrow$

Ausgangssituation und Zielsetzung

Gegeben seien unabhängige, identisch verteilte Zufallsvariablen

$$X_1, \ldots, X_n \sim F \quad \text{mit unbekannter Dichte } f.$$

Zielsetzung:

$$\text{Schätze } f(x) \quad \text{oder} \quad m(x) = \mathbb{E}(Y|X = x)$$

ohne Annahme einer parametrischen Familie.

Grundprinzip: „Lass die Daten sprechen" – Daten bestimmen die Form der Schätzung.

Inhalt

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Empirische Verteilungsfunktion

Die empirische Verteilungsfunktion ist gegeben durch:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{\{X_i \leq x\}}$$

- Die empirische Verteilungsfunktion ist ein konsistenter Schätzer für die Verteilungsfunktion F.
- Sie ist jedoch eine Treppenfunktion.

Wie erhalten wir daraus eine Dichte?

Rosenblatt-Schätzer – Grundidee

Grundprinzip: Da $f(x) = F'(x)$, approximiere die Ableitung durch den symmetrischen Differenzenquotienten:

$$f(x) \approx \frac{F(x+h) - F(x-h)}{2h}.$$

Rosenblatt-Schätzer – Grundidee

Grundprinzip: Da $f(x) = F'(x)$, approximiere die Ableitung durch den symmetrischen Differenzenquotienten:

$$f(x) \approx \frac{F(x+h) - F(x-h)}{2h}.$$

Der Schätzer: Ersetze F durch die empirische Verteilungsfunktion F_n:

$$\hat{f}_n(x) = \frac{F_n(x+h) - F_n(x-h)}{2h}.$$

Interpretation: Die relative Häufigkeit der Beobachtungen in $(x-h, x+h]$, normiert durch $2h$, ergibt ein „gleitendes Histogramm".

Rosenblatt-Schätzer – Konsistenz

Konsistenzbedingungen: Für $n \to \infty$ muss gelten:

1. $h \to 0$ (Bias reduzieren: Differenzenquotient approximiert Ableitung besser)
2. $nh \to \infty$ (Varianz reduzieren: genügend Daten im Intervall)

Spannungsverhältnis: h darf nicht zu schnell gegen Null konvergieren.

Typische Wahl: $h \approx n^{-\alpha}$ mit $0 < \alpha < 1$

Inhalt

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Funktionsweise eines Histogramms

- **Funktionsweise:** Zerlegung des Datenraums in Intervalle (Bins) B_k der Breite h. Die Höhe entspricht der relativen Häufigkeit $\frac{n_k}{n}$ normiert durch h, wobei n_k die Anzahl der Beobachtungen in B_k bezeichnet.
- **Formal ist ein Histogramm gegeben durch:**

$$\hat{f}_H(x) = \sum_k \frac{n_k}{nh} \mathbb{1}_{B_k}(x)$$

- Das Histogramm kann damit als Dichteschätzer verwendet werden.

Histogramm – Probleme

- **Unstetigkeit:** Die geschätzte Dichte ist eine Treppenfunktion.
- **Subjektivität:** Das Ergebnis hängt von der Wahl des Startpunkts x_0 und der Bandbreite h ab.

Histogramm vs. Kerndichteschätzung: Visueller Vergleich

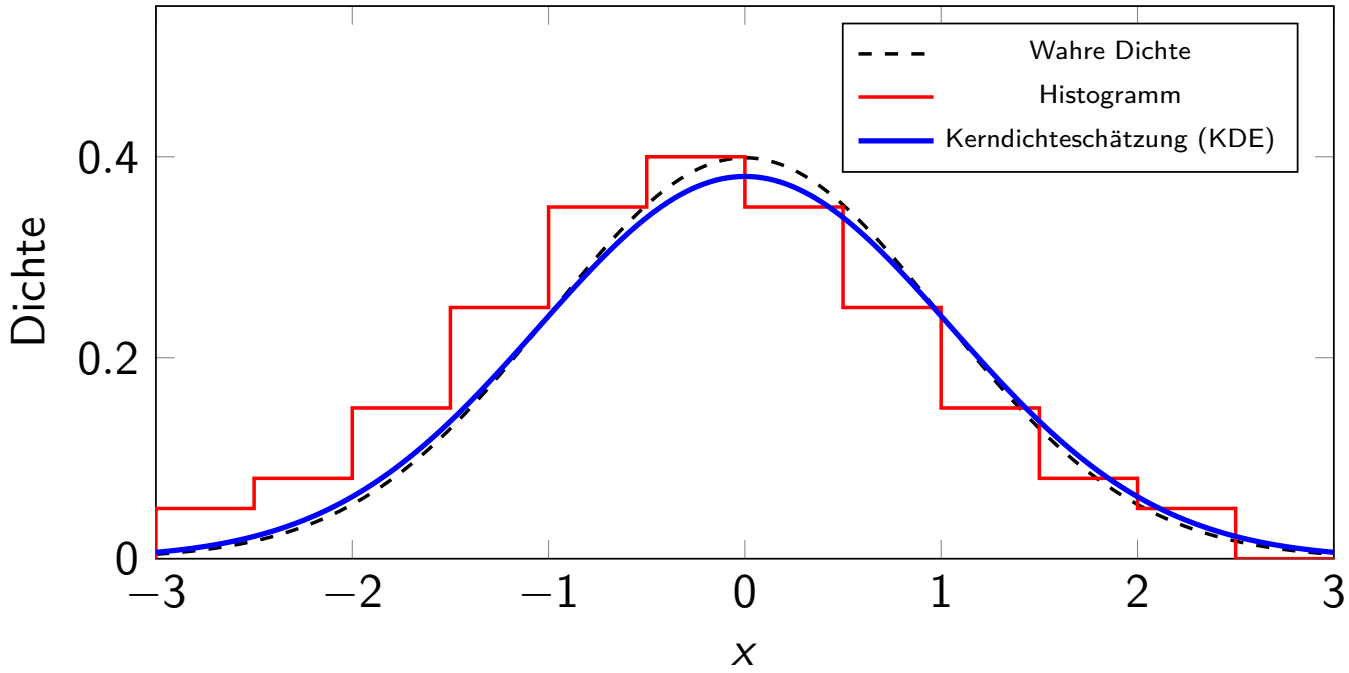

Vorteil KDE: Stetige, glatte Schätzung ohne Sprünge

Histogramm – Optimale Bandbreite

- **Optimale Bandbreite (h):**
  - Scott: $h \approx 3{,}49\, s\, n^{-1/3}$
  - Freedman-Diaconis: $h^* = 2(x_{0.75} - x_{0.25})n^{-1/3}$

Inhalt

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Grundidee der Kerndichteschätzung

- Bei einer Kerndichteschätzung trägt jede Beobachtung zur Schätzung an der Stelle x bei.
- Der Beitrag hängt vom Abstand zur Stelle x ab.
- Es wird eine Gewichtungsfunktion (Kernfunktion) eingeführt.
- Statt harter Intervallabgrenzung erfolgt eine stetige Glättung.

Kerndichteschätzer

Der Kerndichteschätzer ist gegeben durch:

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right),$$

wobei K eine Kernfunktion und $h > 0$ die Bandbreite ist.

Kerndichteschätzer – Wahl des Kerns

Gängige Kernfunktionen:

- **Rechteck-Kern** (Gleichverteilung) – einfachste Kernfunktion, unstetig
- **Gauß-Kern** – glatt, unbeschränkter Träger
- **Epanechnikov-Kern** – optimal (minimiert IMSE)

Praktische Empfehlung: Gauß-Kern meist ausreichend. Bandbreite h ist entscheidender!

Gängige Kernfunktionen – Formeln

Rechteck-Kern (Gleichverteilung auf $[-1, 1]$):

$$K(x) = \begin{cases} \frac{1}{2} & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases}$$

Gängige Kernfunktionen – Formeln

Rechteck-Kern (Gleichverteilung auf $[-1, 1]$):

$$K(x) = \begin{cases} \frac{1}{2} & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases}$$

Gauß-Kern:

$$K(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

Epanechnikov-Kern

Epanechnikov-Kern:

$$K(x) = \begin{cases} \frac{3}{4}(1 - x^2) & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases}$$

Besonderheit des Epanechnikov-Kerns:

- **Theoretisch optimal:** Minimiert den integrierten mittleren quadratischen Fehler ($\text{IMSE} = \int \text{MSE}(x) f(x)\, dx$), der die globale Schätzgüte misst.
- Parabolische Form, kompakter Träger (effizienter zu berechnen).
- Praktisch kaum Unterschied zu Gauß-Kern (Bandbreite h wichtiger!).

Kernfunktion – Mathematische Anforderungen

Ein Kern K muss erfüllen:

1. $K(x) \geq 0$
   verhindert negative Wahrscheinlichkeiten
2. $\int K(x)\,\mathrm{d}x = 1$
   stellt sicher, dass $\hat{f}_n$ eine gültige Dichte ist
3. $K(x) = K(-x)$
   vermeidet systematische Verschiebung
4. $\sigma_K^2 = \int x^2 K(x)\,\mathrm{d}x < \infty$
   notwendig für die Theorie

Wichtig: Die Wahl des Kerns hat meist *geringeren* Einfluss als die Bandbreite h.

Nadaraya-Watson

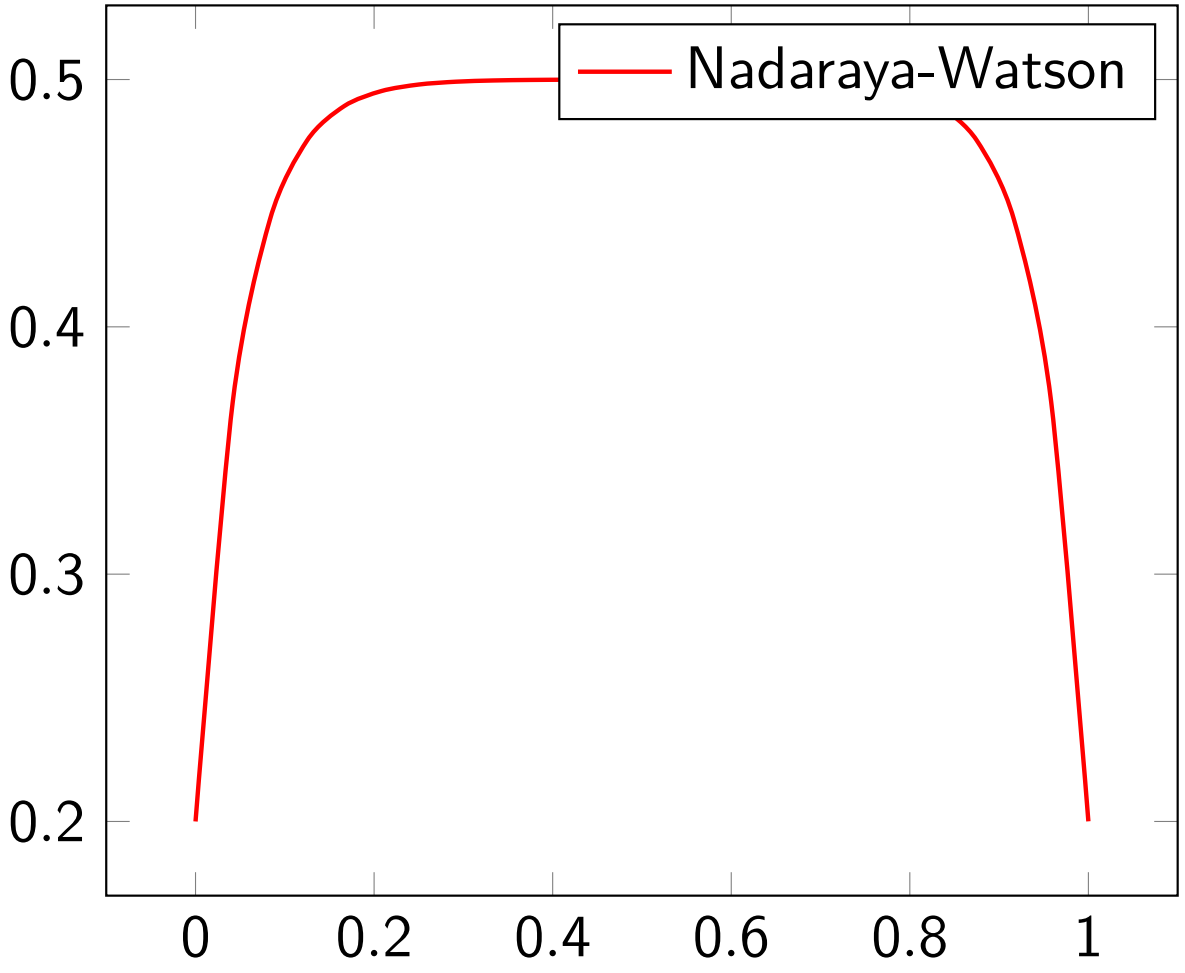

Bandbreitenwahl – Weitere Methoden

Datengetriebene Alternativen:

- **Kreuzvalidierung (Cross-Validation):**
  - Keine Normalverteilungsannahme nötig.
  - Minimiert geschätzten integrierten MSE.
  - Rechenintensiver.
- **Plug-In-Methoden:**
  - Schätzen unbekannte Größen aus Daten.
  - Berechnen optimales h aus asymptotischer MSE-Formel.

Kerndichteschätzung – Rolle der Bandbreite

- Eine kleine Bandbreite führt zu geringer Glättung und hoher Varianz.
- Eine große Bandbreite führt zu starker Glättung und hohem Bias.
- Die Bandbreite ist die zentrale Stellgröße der Kerndichteschätzung.

Bandbreiten-Effekt: Visueller Vergleich

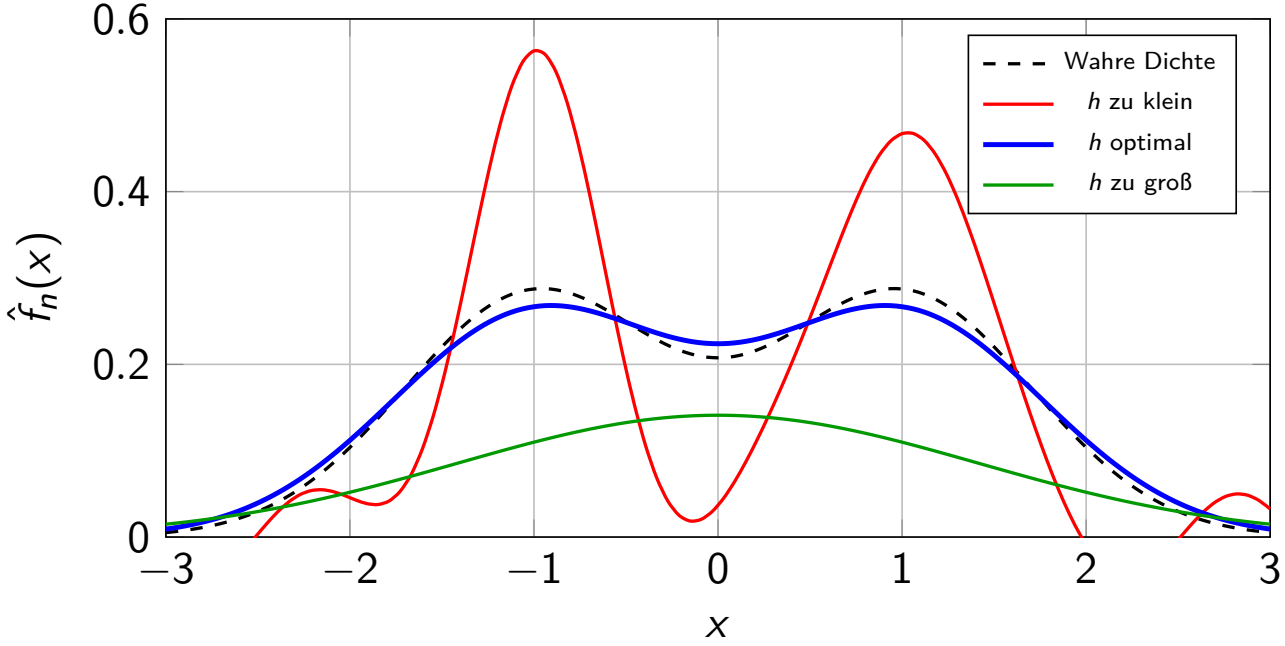

Bimodale Verteilung: h zu klein $\Rightarrow$ überangepasst, h optimal $\Rightarrow$ erfasst beide Modes, h zu groß $\Rightarrow$ verschmiert Struktur

KDE als Faltung

Der Kerndichteschätzer lässt sich als Faltung schreiben:

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \quad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right).$$

KDE als Faltung

Der Kerndichteschätzer lässt sich als Faltung schreiben:

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \quad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right).$$

Der Erwartungswert ergibt sich als:

$$\mathbb{E}[\hat{f}_n(x)] = (K_h * f)(x).$$

Bias = Glättungsfehler der Faltung

KDE als Faltung – Interpretation

Was bedeutet die Faltung?

- Der Erwartungswert ist eine *geglättete* Version von f.
- Je breiter der Kern (größeres h), desto stärker die Glättung.
- Feine Strukturen werden „verschmiert".
- Dies erklärt, warum die Wahl von h so kritisch ist.

Bias–Varianz-Tradeoff

Unter Regularitätsannahmen:

$$\mathrm{Bias}(\hat{f}_n(x)) = O(h^2), \quad \mathrm{Var}(\hat{f}_n(x)) = O\left(\frac{1}{nh}\right)$$

Bias–Varianz-Tradeoff

Unter Regularitätsannahmen:

$$\mathrm{Bias}(\hat{f}_n(x)) = O(h^2), \quad \mathrm{Var}(\hat{f}_n(x)) = O\left(\frac{1}{nh}\right)$$

MSE-Zerlegung:

$$\mathrm{MSE}(x) = \mathrm{Bias}^2 + \mathrm{Var} = O(h^4) + O\left(\frac{1}{nh}\right)$$

Bias–Varianz-Tradeoff

Unter Regularitätsannahmen:

$$\mathrm{Bias}(\hat{f}_n(x)) = O(h^2), \quad \mathrm{Var}(\hat{f}_n(x)) = O\left(\frac{1}{nh}\right)$$

MSE-Zerlegung:

$$\mathrm{MSE}(x) = \mathrm{Bias}^2 + \mathrm{Var} = O(h^4) + O\left(\frac{1}{nh}\right)$$

Optimierung: Minimiere MSE durch Ableiten nach h:

$$\frac{d}{dh}\left[C_1 h^4 + \frac{C_2}{nh}\right] = 4C_1 h^3 - \frac{C_2}{nh^2} \stackrel{!}{=} 0$$

$\Rightarrow h_{\mathrm{opt}} \sim n^{-1/5}$ und $\mathrm{MSE}_{\mathrm{opt}} \sim n^{-4/5}$

Bezug zum Rosenblatt-Schätzer

- Der Rosenblatt-Schätzer ist ein Spezialfall des Kerndichteschätzers mit Rechteck-Kern und kompaktem Träger.
- Die Kerndichteschätzung verallgemeinert diesen Ansatz.
- Sie liefert stetige Schätzfunktionen.

Vorteile der Kerndichteschätzung

- Stetige und glatte Schätzfunktion.
- Flexibel einsetzbar.
- Gute theoretische Eigenschaften.
- Grundlage für weiterführende nichtparametrische Verfahren.

Inhalt

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Nichtparametrische Regression – Einführung

Nadaraya–Watson-Schätzer:

$$\hat{m}_{NW}(x) = \frac{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right) Y_i}{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right)}$$

Der Nadaraya-Watson-Schätzer schätzt $m(x)$ als gewichteten Mittelwert der umliegenden Y-Werte.

Nichtparametrische Regression – Zielsetzung

Ziel:

- Schätzung des funktionalen Zusammenhangs zwischen X und Y.
- Ohne Annahme einer konkreten parametrischen Form für $m(x)$.

Unterschied zur linearen Regression:

- Kein globales lineares Modell.
- Lokale Anpassung an die Datenstruktur.

Nichtparametrische Regression – Lokale Glättung

Grundidee:

- Punkte mit ähnlichen X-Werten liefern ähnliche Informationen über $m(x)$.
- Beobachtungen in der Nähe von x werden stärker gewichtet.

Umsetzung:

- Die Gewichtung erfolgt über eine Kernfunktion K.
- Die Bandbreite h bestimmt die Größe der lokalen Umgebung.

Nadaraya–Watson-Schätzer – Interpretation

Interpretation des Schätzers:

- $\hat{m}_{NW}(x)$ ist ein gewichteter Mittelwert der Y_i.
- Die Gewichte hängen vom Abstand zwischen X_i und x ab.
- Je näher X_i an x liegt, desto größer ist sein Einfluss.

Nichtparametrische Regression – Rolle der Bandbreite

Einfluss der Bandbreite h:

- Ein kleines h führt zu starker lokaler Anpassung und hoher Varianz.
- Ein großes h führt zu starker Glättung und höherem Bias.
- Es gilt derselbe Bias-Varianz-Tradeoff wie bei der KDE.

Nichtparametrische Regression – Vorteile und Grenzen

Vorteile:

- Hohe Flexibilität.
- Keine Modellfehlanpassung durch falsche Annahmen.

Grenzen:

- Die Wahl der Bandbreite ist entscheidend.
- Randprobleme bei kleinen Stichproben.

Boundary Bias Problem

Problem an den Rändern:

- Der Nadaraya-Watson-Schätzer hat starken Bias an Datengrenzen.
- Weniger Datenpunkte in der Umgebung verfügbar.
- Asymmetrische Gewichtung führt zu Verzerrung.

Lösungsansätze:

- **Lokale Polynomschätzer:** Anpassung lokaler Polynome (linear, quadratisch)
- Reduzieren Randbias erheblich
- Verallgemeinerung des Nadaraya-Watson-Ansatzes

Boundary Bias: Visualisierung

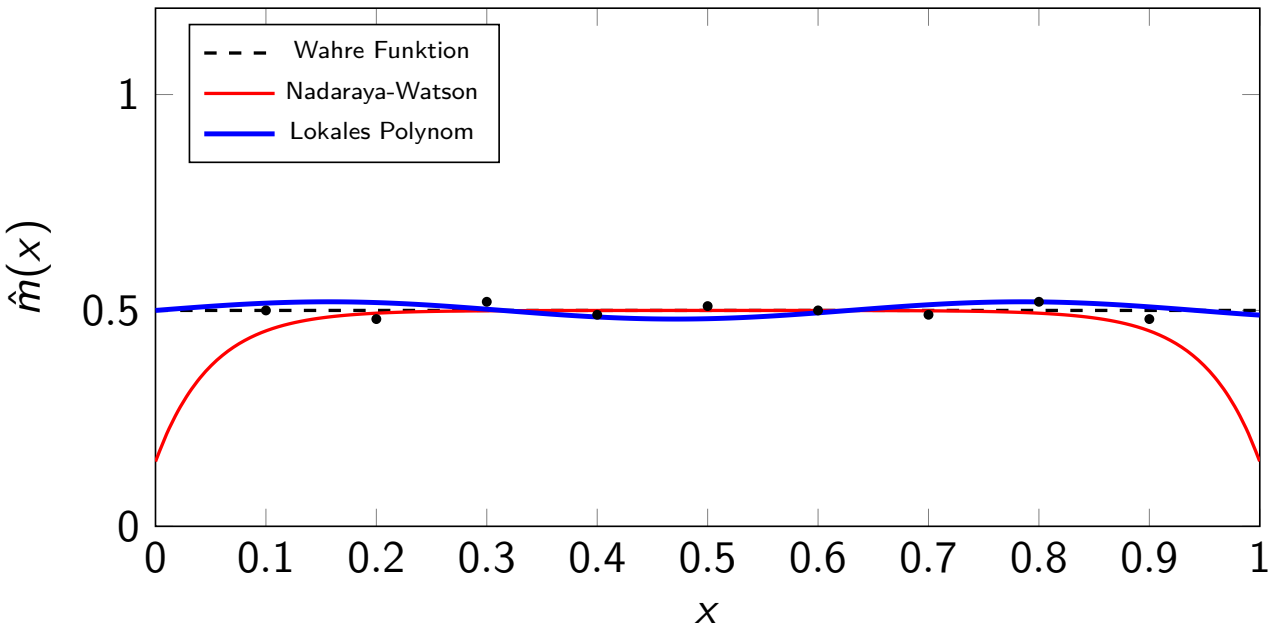

An Rändern: NW-Schätzer verzerrt (nach unten), lokales Polynom korrigiert

Zusammenhang zur Kerndichteschätzung

Gemeinsames Prinzip:

- Verwendung von Kernfunktionen.
- Lokale Gewichtung von Beobachtungen.

Unterschied:

- Dichteschätzung: Schätzung von $f(x)$.
- Regression: Schätzung von $m(x) = \mathbb{E}(Y|X = x)$.

Strukturelle Sicht

Der Regressionsfunktionswert lässt sich schreiben als:

$$m(x) = \frac{\int y\, f_{XY}(x, y)\, dy}{f_X(x)}.$$

Der Nadaraya-Watson-Schätzer ergibt sich daraus als Quotient von Kerndichteschätzern:

$$\hat{m}(x) = \frac{\hat{r}(x)}{\hat{f}_X(x)}, \quad \hat{r}(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right) Y_i.$$

Inhalt

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Robuste Lineare Regression – Motivation

Verbindung zur nichtparametrischen Statistik:

- Wie die KDE verzichtet auch robuste Regression auf starke Verteilungsannahmen.
- Beide zielen auf Robustheit durch reduzierte Verteilungsannahmen und lokale Gewichtung von Datenpunkten.

Ziel:

- Schätzung eines linearen Zusammenhangs zwischen X und Y.
- Geringe Empfindlichkeit gegenüber Ausreißern.

Problem der klassischen Regression:

- Basiert auf quadratischen Fehlern (OLS).
- Einzelne Ausreißer können die Schätzung stark verzerren.

Robuste Lineare Regression – Grundidee

Zentrale Idee:

- Betrachtung von Steigungen zwischen Beobachtungspaaren.
- Verzicht auf Minimierung einer globalen Fehlerfunktion.

Konsequenz:

- Die Schätzung basiert auf Lageparametern (Median).
- Hohe Robustheit gegenüber extremen Werten.

Robuste Lineare Regression – Rolle des Medians

Warum der Median?

- Unempfindlich gegenüber einzelnen Ausreißern.
- Repräsentiert die zentrale Tendenz der Steigungen.

Vergleich:

- Mittelwert: stark ausreißerempfindlich.
- Median: robust gegenüber extremen Beobachtungen.

Robuste Regression vs. Kleinste Quadrate

Methode der kleinsten Quadrate:

- Minimiert die Summe der quadrierten Residuen.
- Sehr empfindlich gegenüber Ausreißern.

Theil- bzw. Theil–Sen-Schätzer:

- Basieren auf Medianschätzung.
- Deutlich robuster gegenüber Ausreißern.

Theil–Sen-Schätzer – Eigenschaften

Wichtige Eigenschaften:

- Hoher Breakdown-Point.
- Konsistent unter milden Voraussetzungen.
- Geeignet bei verrauschten Daten.

Einsatzgebiet:

- Explorative Datenanalyse.
- Datensätze mit möglichen Ausreißern.

Robuste Lineare Regression – Grenzen

Einschränkungen:

- Höherer Rechenaufwand bei großen Stichproben.
- Beschränkt auf lineare Zusammenhänge.

Abgrenzung:

- Nichtparametrische Regression bietet höhere Flexibilität.
- Dafür geringere Interpretierbarkeit.

Theil-Schätzer – Einführung und Formel

- **Theil-Methode I:** Steigung zwischen Paaren $(i, i + n/2)$, Median als Schätzer.
- **Theil-Sen-Schätzer (Methode II):** Median der Steigungen H_{ij} zwischen allen Paaren $i < j$:

$$H_{ij} = \frac{Y_j - Y_i}{X_j - X_i}$$

Der Schätzer für den Anstieg β ist der Median dieser Steigungen.

Inhalt

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Take-Home Messages

- Nichtparametrisch = lokal + datengetrieben.
- KDE = Faltung mit empirischem Maß.
- Bandbreite bestimmt Konvergenz.
- Regression folgt demselben Prinzip.
- Robustheit schützt vor Ausreißern.

Fazit und Ausblick

- **Flexibilität:** Nichtparametrische Methoden passen sich den Daten an.
- **Parameter h:** Kritischer Schritt, Balance zwischen Bias und Varianz.
- **Robustheit:** Verfahren wie der Theil-Sen-Schätzer bieten robuste Alternativen zur klassischen Regression, besonders bei Ausreißern.

Literaturverzeichnis I

[BT94] Herbert Büning und Götz Trenkler. *Nichtparametrische statistische Methoden*. Berlin, Boston: De Gruyter, 1994. ISBN: 9783110902990. DOI: doi:10.1515/9783110902990. URL: https://doi.org/10.1515/9783110902990.

[Epa69] V. A. Epanechnikov. „Non-Parametric Estimation of a Multivariate Probability Density“. In: *Theory of Probability & Its Applications* 14.1 (1969), S. 153–158.

[FD81] David Freedman und Persi Diaconis. „On the Histogram as a Density Estimator: L2 Theory“. In: *Zeitschrift für Wahrscheinlichkeitstheorie und Verwandte Gebiete* 57.4 (1981), S. 453–476.

[Nad64] E. A. Nadaraya. „On Estimating Regression“. In: *Theory of Probability & Its Applications* 9.1 (1964), S. 141–142.

Literaturverzeichnis II

[Ros56] Murray Rosenblatt. „Remarks on Some Nonparametric Estimates of a Density Function“. In: *The Annals of Mathematical Statistics* 27.3 (1956), S. 832–837.

[Sco79] David W. Scott. „On Optimal and Data-Based Histograms“. In: *Biometrika* 66.3 (1979), S. 605–610.

[Sen68] Pranab Kumar Sen. „Estimates of the Regression Coefficient Based on Kendall's Tau“. In: *Journal of the American Statistical Association* 63.324 (1968), S. 1379–1389.

[Sil86] Bernard W. Silverman. *Density Estimation for Statistics and Data Analysis*. Monographs on Statistics and Applied Probability. London: Chapman und Hall, 1986. ISBN: 978-0412246203.

Literaturverzeichnis III

[The50] Henri Theil. „A Rank-Invariant Method of Linear and Polynomial Regression Analysis“. In: *Proceedings of the Koninklijke Nederlandse Akademie van Wetenschappen* 53 (1950), S. 386–392, 521–525, 1397–1412.

[Wat64] Geoffrey S. Watson. „Smooth Regression Analysis“. In: *Sankhyā: The Indian Journal of Statistics, Series A* 26.4 (1964), S. 359–372.