Einführung in die Kerndichteschätzung

Yavuzâlp Dal

Angewandte Statistik

1. März 2026

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Einleitung & Motivation

Parametrisch

- Annahme: Verteilung ist bekannt (z. B. Normalverteilung)
- Wenige Parameter (μ, σ^2)
- Schätzung durch Maximum-Likelihood

Problem:

- Oft zu starr bei unbekannter Verteilung
- Starke Kopplung an unsicheren Annahmen!

Einleitung & Motivation

Parametrisch

- Annahme: Verteilung ist bekannt (z. B. Normalverteilung)
- Wenige Parameter (μ, σ^2)
- Schätzung durch Maximum-Likelihood

Nichtparametrisch (KDE)

- Keine parametrische Familie vorgegeben
- Annahmen: X stetig, f glatt (mind. zweimal differenzierbar)
- Schätzung über Kernfunktion K und Bandbreite h

Problem:

- Oft zu starr bei unbekannter Verteilung
- Starke Kopplung an unsicheren Annahmen!

Vorteil:

- Flexibel, datengetrieben
- Erfasst komplexe Strukturen

Modellannahme vs. Datengetrieben

$\longleftrightarrow$

Einfachheit vs. Flexibilität

$\longleftrightarrow$

Ausgangssituation und Zielsetzung

Gegeben seien u.u.i.d. Zufallsvariablen

$$X_1, \ldots, X_n \sim F \quad \text{mit unbekannter Dichte } f.$$

Zielsetzung [BT94]:

$$\text{Schätze } f(x) \text{ oder } m(x) = \mathbb{E}(Y|X = x)$$

ohne Annahme einer parametrischen Familie.

Grundprinzip: „Let the data speak" – Daten bestimmen die Form der Schätzung

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Empirische Verteilungsfunktion

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{\{X_i \leq x\}}$$

- Konsistent für F
- Aber: Treppenfunktion

Wie erhalten wir daraus eine Dichte?

Der Rosenblatt-Schätzer – Grundidee

Grundprinzip: Da $f(x) = F'(x)$, approximiere die Ableitung durch symmetrischen Differenzenquotienten [Ros56]:

$$f(x) \approx \frac{F(x+h) - F(x-h)}{2h}$$

Der Rosenblatt-Schätzer – Grundidee

Grundprinzip: Da $f(x) = F'(x)$, approximiere die Ableitung durch symmetrischen Differenzenquotienten [Ros56]:

$$f(x) \approx \frac{F(x+h) - F(x-h)}{2h}$$

Der Schätzer: Ersetze F durch empirische Verteilungsfunktion F_n:

$$\hat{f}_n(x) = \frac{F_n(x+h) - F_n(x-h)}{2h} \tag{1}$$

Interpretation: Relative Häufigkeit der Beobachtungen in $(x-h, x+h]$, normiert durch $2h$ – ein „gleitendes Histogramm“.

Der Rosenblatt-Schätzer – Konsistenz

Konsistenzbedingungen: Für $n \to \infty$ muss gelten:

1. $h \to 0$ (Bias reduzieren: Differenzenquotient approximiert Ableitung besser)
2. $nh \to \infty$ (Varianz reduzieren: genügend Daten im Intervall)

Spannungsverhältnis: h darf nicht zu schnell gegen Null konvergieren.
Typisch: $h \sim n^{-\alpha}$ mit $0 < \alpha < 1$

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Das Histogramm (Der Klassiker)

- **Funktionsweise:** Zerlegung des Datenraums in Boxen (Bins) der Breite h. Die Höhe der Box entspricht der relativen Häufigkeit $\frac{n_k}{n}$ normiert durch h.
- **Formal:**

$$\hat{f}_H(x) = \sum_k \frac{n_k}{nh} \mathbb{1}_{B_k}(x)$$

Das Histogramm (Probleme)

- **Probleme:**
  - Unstetigkeit: Die geschätzte Dichte ist eine Treppenfunktion.
  - Subjektivität: Abhängig von x_0 und h.

Histogramm vs. KDE: Visueller Vergleich

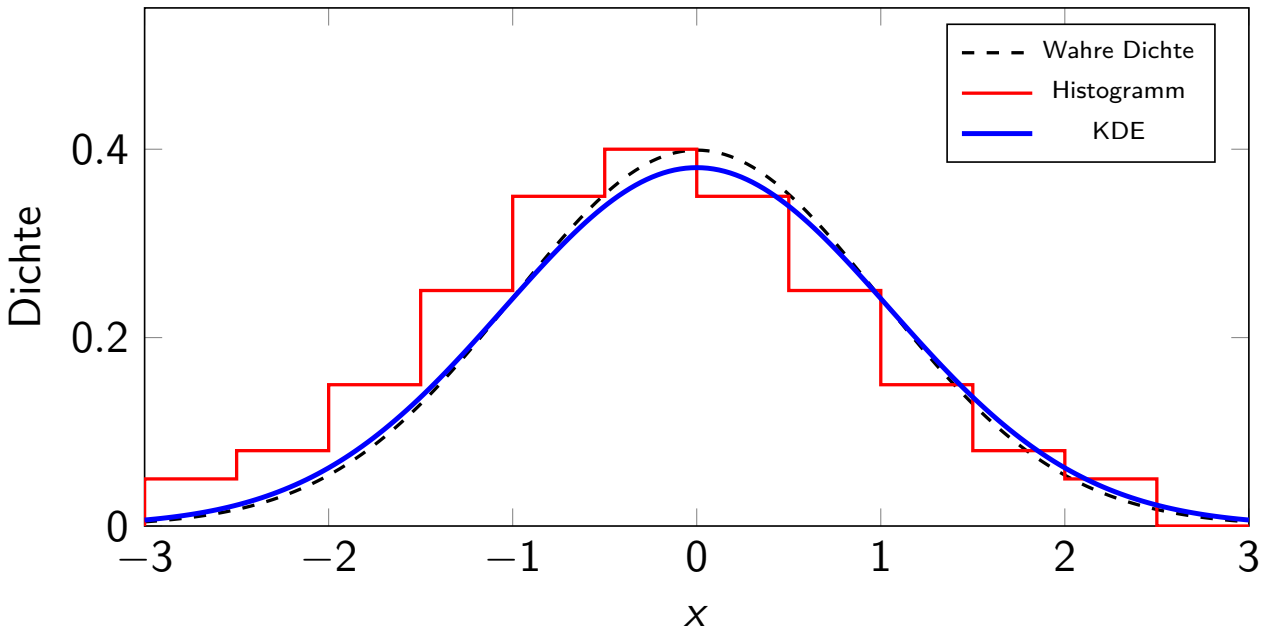

Vorteil KDE: Stetige, glatte Schätzung ohne Sprünge

Das Histogramm (Optimale Bandbreite)

- **Optimale Bandbreite (h):**
  - Scott [Sco79]: $h \approx 3.49sn^{-1/3}$
  - Freedman-Diaconis [FD81]: $h^* = 2(x_{0.75} - x_{0.25})n^{-1/3}$

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Grundidee der Kerndichteschätzung

- Jede Beobachtung trägt zur Schätzung an der Stelle x bei
- Der Beitrag hängt vom Abstand zu x ab

- Einführung einer Gewichtungsfunktion (Kernfunktion)
- Glättung statt harter Intervallabgrenzung

Kernschätzer (KDE) - Einführung

- **Der Schätzer:**

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right) \tag{2}$$

- K: Kernfunktion
- $h > 0$: Bandbreite

Kernschätzer (KDE) – Wahl des Kerns

Gängige Kernfunktionen:

- **Rechteck-Kern** (Uniform) – einfachst, unstetig
- **Gauß-Kern** – glatt, unbeschränkter Träger
- **Epanechnikov-Kern** – optimal (minimiert IMSE)

Praktische Empfehlung: Gauß-Kern meist ausreichend. Bandbreite h ist entscheidender!

Gängige Kernfunktionen – Formeln

Rechteck-Kern (Uniform):

$$K(x) = \begin{cases} \frac{1}{2} & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases}$$

Gängige Kernfunktionen – Formeln

Rechteck-Kern (Uniform):

$$K(x) = \begin{cases} \frac{1}{2} & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases}$$

Gauß-Kern:

$$K(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

Epanechnikov-Kern – Der Optimale

Formel [Epa69]:

$$K(x) = \begin{cases} \frac{3}{4}(1 - x^2) & \text{falls } |x| \leq 1 \\ 0 & \text{sonst} \end{cases}$$

Besonderheit:

- **Theoretisch optimal:** Minimiert den integrierten mittleren quadratischen Fehler (IMSE)
- IMSE $= \int \text{MSE}(x) f(x)\, dx$ – misst globale Schätzgüte
- Parabolische Form, kompakter Träger (effizienter zu berechnen)
- Praktisch kaum Unterschied zu Gauß-Kern (Bandbreite h wichtiger!)

Kernfunktion – Mathematische Anforderungen

Ein Kern K muss erfüllen:

1. $K(x) \geq 0$ (Nicht-Negativität) – verhindert negative Wahrscheinlichkeiten
2. $\int K(x)\,dx = 1$ (Normierung) – stellt sicher, dass $\hat{f}_n$ gültige Dichte ist
3. $K(x) = K(-x)$ (Symmetrie) – vermeidet systematische Verschiebung
4. $\sigma_K^2 = \int x^2 K(x)\,dx < \infty$ (Endliche Varianz) – notwendig für Theorie

Wichtig: Kernwahl hat meist *geringeren* Einfluss als Bandbreite h!

Kernfunktion - Mathematische Anforderungen

Ein Kern K muss erfüllen:

1. $K(x) \geq 0$
   verhindert negative Wahrscheinlichkeiten
2. $\int K(x)\,\mathrm{d}x = 1$
   stellt sicher, dass $\hat{f}_n$ eine gültige Dichte ist
3. $K(x) = K(-x)$
   vermeidet systematische Verschiebung
4. $\sigma_K^2 = \int x^2 K(x)\,\mathrm{d}x < \infty$
   notwendig für die Theorie

Wichtig: Die Wahl des Kerns hat meist *geringeren* Einfluss als die Bandbreite h.

Nadaraya-Watson

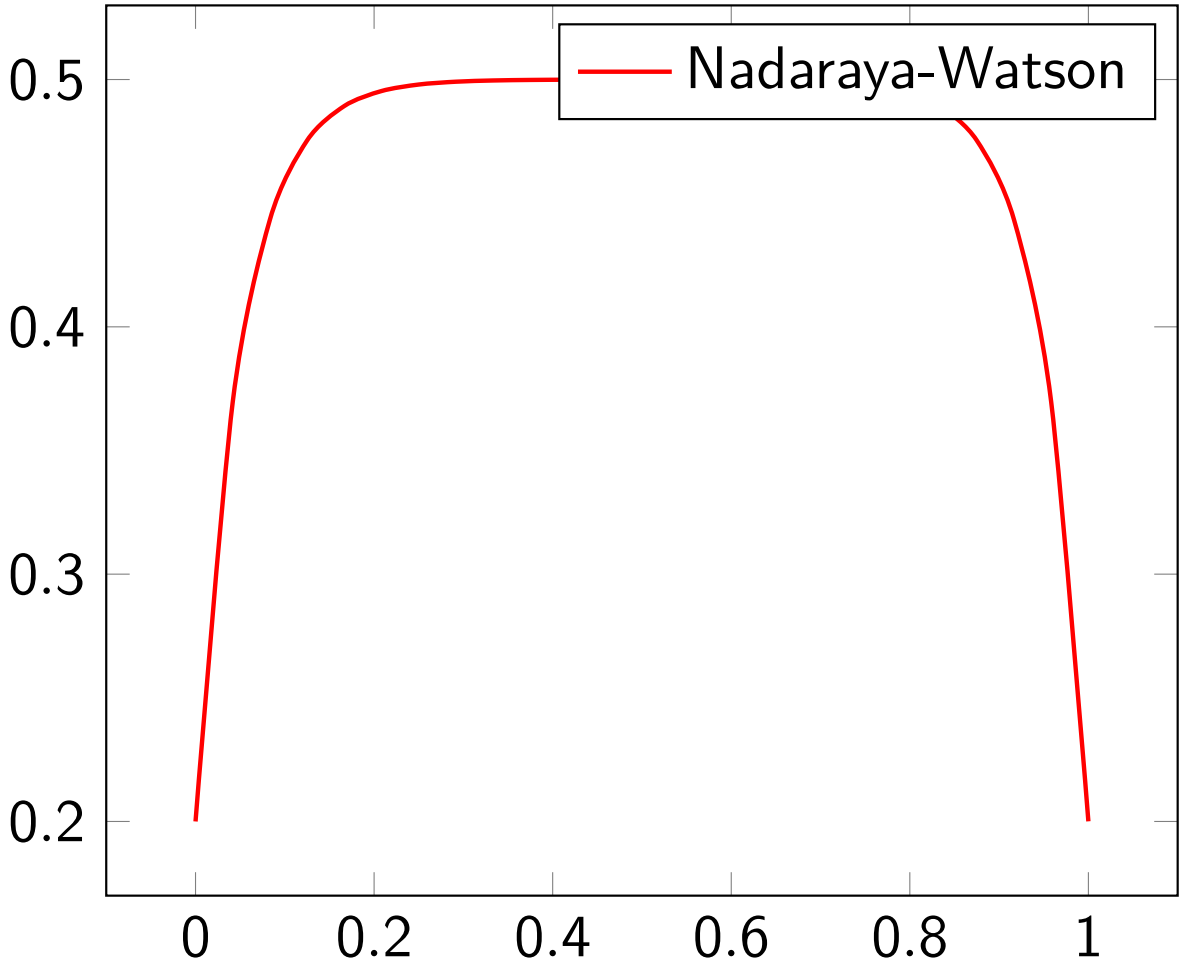

Bandbreitenwahl – Weitere Methoden

Datengetriebene Alternativen:

- **Kreuzvalidierung (Cross-Validation):**
  - Keine Normalverteilungsannahme nötig
  - Minimiert geschätzten integrierten MSE
  - Rechenintensiver
- **Plug-In-Methoden:**
  - Schätzen unbekannte Größen aus Daten
  - Berechnen optimales h aus asymptotischer MSE-Formel

Kerndichteschätzung – Rolle der Bandbreite

- Kleine Bandbreite: geringe Glättung, hohe Varianz
- Große Bandbreite: starke Glättung, hoher Bias
- Zentrale Stellgröße der Kerndichteschätzung

Bandbreiten-Effekt: Visueller Vergleich

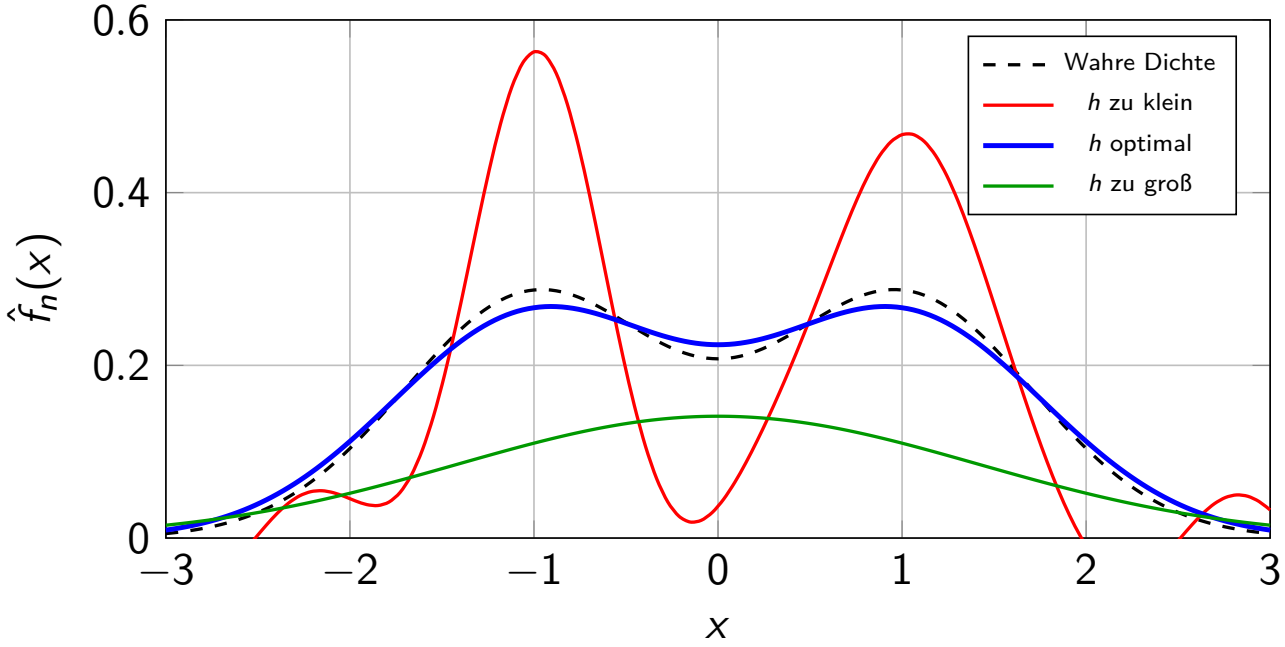

Bimodale Verteilung: h zu klein $\Rightarrow$ überangepasst, h optimal $\Rightarrow$ erfasst beide Modes, h zu groß $\Rightarrow$ verschmiert Struktur

KDE als Faltung

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \quad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right)$$

KDE als Faltung

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \quad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right)$$

$$\mathbb{E}[\hat{f}_n(x)] = (K_h * f)(x)$$

Bias = Glättungsfehler der Faltung

KDE als Faltung – Interpretation

Was bedeutet die Faltung?

- Der Erwartungswert ist eine *geglättete* Version von f
- Je breiter der Kern (größeres h), desto stärker die Glättung
- Feine Strukturen werden „verschmiert“
- Dies erklärt, warum die Wahl von h so kritisch ist

Bias–Varianz-Tradeoff

Unter Regularitätsannahmen:

$$\mathrm{Bias}(\hat{f}_n(x)) = O(h^2), \quad \mathrm{Var}(\hat{f}_n(x)) = O\left(\frac{1}{nh}\right)$$

Bias–Varianz-Tradeoff

Unter Regularitätsannahmen:

$$\mathrm{Bias}(\hat{f}_n(x)) = O(h^2), \quad \mathrm{Var}(\hat{f}_n(x)) = O\left(\frac{1}{nh}\right)$$

MSE-Zerlegung:

$$\mathrm{MSE}(x) = \mathrm{Bias}^2 + \mathrm{Var} = O(h^4) + O\left(\frac{1}{nh}\right)$$

Bias–Varianz-Tradeoff

Unter Regularitätsannahmen:

$$\mathrm{Bias}(\hat{f}_n(x)) = O(h^2), \quad \mathrm{Var}(\hat{f}_n(x)) = O\left(\frac{1}{nh}\right)$$

MSE-Zerlegung:

$$\mathrm{MSE}(x) = \mathrm{Bias}^2 + \mathrm{Var} = O(h^4) + O\left(\frac{1}{nh}\right)$$

Optimierung: Minimiere MSE durch Ableiten nach h:

$$\frac{d}{dh}\left[C_1 h^4 + \frac{C_2}{nh}\right] = 4C_1 h^3 - \frac{C_2}{nh^2} \stackrel{!}{=} 0$$

$\Rightarrow h_{\mathrm{opt}} \sim n^{-1/5}$ und $\mathrm{MSE}_{\mathrm{opt}} \sim n^{-4/5}$

Bezug zum Rosenblatt-Schätzer

- Rosenblatt-Schätzer als Spezialfall
- Rechteckkern mit kompakter Unterstützung

- Kerndichteschätzung verallgemeinert den Ansatz
- Liefert stetige Schätzfunktionen

Vorteile der Kerndichteschätzung

- Stetige und glatte Schätzfunktion
- Flexibel einsetzbar
- Gute theoretische Eigenschaften
- Grundlage für weiterführende nichtparametrische Verfahren

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Nichtparametrische Regression – Einführung

Nadaraya–Watson-Schätzer [Nad64; Wat64]:

$$\hat{m}_{NW}(x) = \frac{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right) Y_i}{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right)} \tag{3}$$

- Schätzung von $m(x)$ als gewichteter Mittelwert der umliegenden Y-Werte.

Nichtparametrische Regression – Zielsetzung

Ziel:

- Schätzung des funktionalen Zusammenhangs zwischen X und Y
- Ohne Annahme einer konkreten parametrischen Form für $m(x)$

Unterschied zur linearen Regression:

- Kein globales lineares Modell
- Lokale Anpassung an die Datenstruktur

Nichtparametrische Regression – Lokale Glättung

Grundidee:

- Punkte mit ähnlichen X-Werten liefern ähnliche Informationen über $m(x)$
- Beobachtungen in der Nähe von x werden stärker gewichtet

Umsetzung:

- Gewichtung erfolgt über eine Kernfunktion K
- Die Bandbreite h bestimmt die Größe der lokalen Umgebung

Nadaraya–Watson-Schätzer – Interpretation

Interpretation des Schätzers:

- $\hat{m}_{NW}(x)$ ist ein gewichteter Mittelwert der Y_i
- Gewichte hängen vom Abstand zwischen X_i und x ab

Eigenschaft:

- Je näher X_i an x liegt, desto größer ist sein Einfluss

Nichtparametrische Regression – Rolle der Bandbreite

Einfluss der Bandbreite h:

- Kleines h: starke lokale Anpassung, hohe Varianz
- Großes h: starke Glättung, höherer Bias

Analogie zur Dichteschätzung:

- Gleicher Bias-Varianz-Tradeoff wie bei der KDE

Nichtparametrische Regression – Vorteile und Grenzen

Vorteile:

- Hohe Flexibilität
- Keine Modellfehlanpassung durch falsche Annahmen

Grenzen:

- Wahl der Bandbreite entscheidend
- Randprobleme bei kleinen Stichproben

Boundary Bias Problem

Problem an den Rändern:

- Nadaraya-Watson-Schätzer hat starken Bias an Datengrenzen
- Weniger Datenpunkte in der Umgebung verfügbar
- Asymmetrische Gewichtung führt zu Verzerrung

Lösungsansätze:

- **Lokale Polynomschätzer:** Anpassung lokaler Polynome (linear, quadratisch)
- Reduzieren Randbias erheblich
- Verallgemeinerung des Nadaraya-Watson-Ansatzes

Boundary Bias: Visualisierung

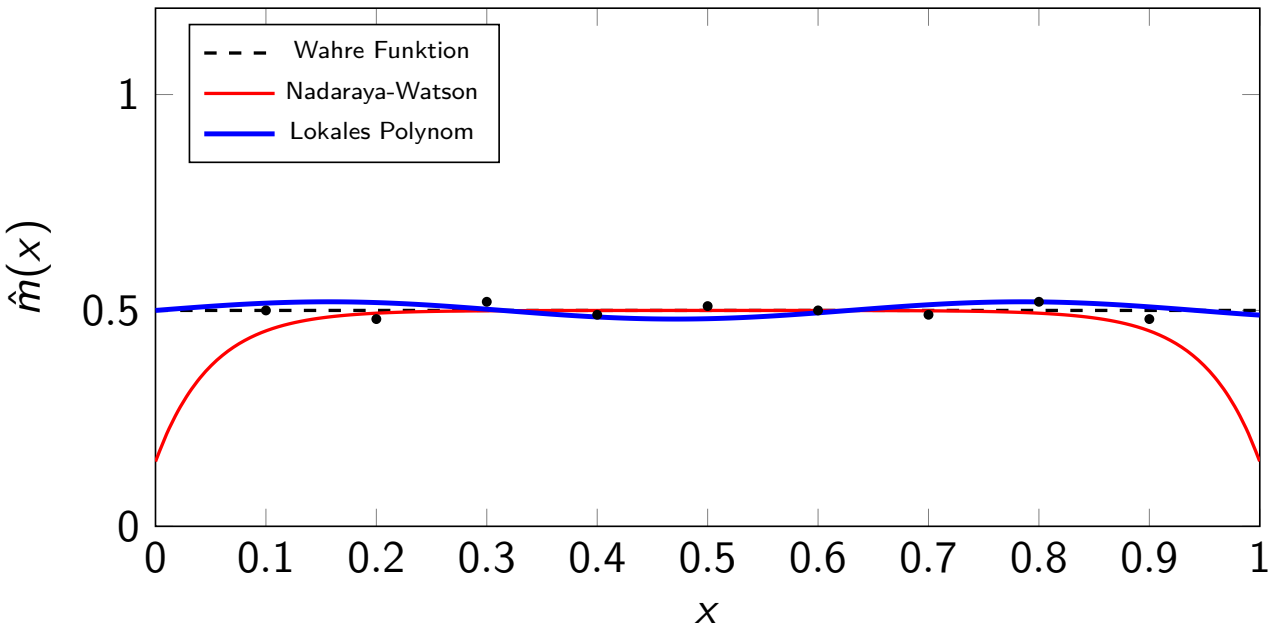

An Rändern: NW-Schätzer verzerrt (nach unten), lokales Polynom korrigiert

Zusammenhang zur Kerndichteschätzung

Gemeinsames Prinzip:

- Verwendung von Kernfunktionen
- Lokale Gewichtung von Beobachtungen

Unterschied:

- Dichteschätzung: Schätzung von $f(x)$
- Regression: Schätzung von $m(x) = \mathbb{E}(Y|X = x)$

Strukturelle Sicht

$$m(x) = \frac{\int y\, f_{XY}(x,y)\, dy}{f_X(x)}$$

$$\hat{m}(x) = \frac{\hat{r}(x)}{\hat{f}_X(x)}, \quad \hat{r}(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right) Y_i$$

Quotient von Kerndichteschätzern

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Robuste Lineare Regression – Motivation

Verbindung zur nichtparametrischen Statistik:

- Wie KDE verzichtet auch robuste Regression auf starke Verteilungsannahmen
- Beide zielen auf Robustheit durch reduzierte Verteilungsannahmen und lokale Gewichtung von Datenpunkten

Ziel:

- Schätzung eines linearen Zusammenhangs zwischen X und Y
- Geringe Empfindlichkeit gegenüber Ausreißern

Problem der klassischen Regression:

- Basiert auf quadratischen Fehlern (OLS)
- Einzelne Ausreißer können Schätzung stark verzerren

Robuste Lineare Regression – Grundidee

Zentrale Idee:

- Betrachtung von Steigungen zwischen Beobachtungspaaren
- Verzicht auf Minimierung einer globalen Fehlerfunktion

Konsequenz:

- Schätzung basiert auf Lageparametern (Median)
- Hohe Robustheit gegenüber extremen Werten

Robuste Lineare Regression – Rolle des Medians

Warum der Median?

- Unempfindlich gegenüber einzelnen Ausreißern
- Repräsentiert die zentrale Tendenz der Steigungen

Vergleich:

- Mittelwert: stark ausreißerempfindlich
- Median: robust gegenüber extremen Beobachtungen

Robuste Regression vs. Kleinste Quadrate

Methode der kleinsten Quadrate:

- Minimiert die Summe der quadrierten Residuen
- Sehr empfindlich gegenüber Ausreißern

Theil- bzw. Theil–Sen-Schätzer:

- Basieren auf Medianschätzung
- Deutlich robuster gegenüber Ausreißern

Theil–Sen-Schätzer – Eigenschaften

Wichtige Eigenschaften:

- Hoher Breakdown-Point
- Konsistent unter milden Voraussetzungen
- Geeignet bei verrauschten Daten

Einsatzgebiet:

- Explorative Datenanalyse
- Datensätze mit möglichen Ausreißern

Robuste Lineare Regression – Grenzen

Einschränkungen:

- Höherer Rechenaufwand bei großen Stichproben
- Beschränkt auf lineare Zusammenhänge

Abgrenzung:

- Nichtparametrische Regression bietet höhere Flexibilität
- Dafür geringere Interpretierbarkeit

Robuste Lineare Regression (Theil-Schätzer) - Einführung

- **Theil-Methode I [The50]:** Steigung zwischen Paaren $(i, i + n/2)$, Median als Schätzer.
- **Theil-Sen-Schätzer (Methode II) [The50; Sen68]:** Median der Steigungen zwischen allen Paaren $i < j$:

Robuste Lineare Regression (Theil-Schätzer) - Formel

$$H_{ij} = \frac{Y_j - Y_i}{X_j - X_i} \tag{4}$$

- Der Schätzer für den Anstieg β ist der Median dieser Steigungen.

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Take-Home Messages

- Nichtparametrisch = lokal + datengetrieben
- KDE = Faltung mit empirischem Maß
- Bandbreite bestimmt Konvergenz
- Regression folgt demselben Prinzip
- Robustheit schützt vor Ausreißern

Fazit und Ausblick

- **Flexibilität:** Nichtparametrische Methoden passen sich den Daten an.
- **Parameter** h**:** Kritischer Schritt, Balance zwischen Bias und Varianz.

Fazit und Ausblick (Fortsetzung)

- **Robustheit:** Verfahren wie der Theil-Sen-Schätzer bieten robuste Alternativen zur klassischen Regression, besonders bei Ausreißern.

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Literaturverzeichnis I

[BT94] Herbert Büning und Götz Trenkler. *Nichtparametrische statistische Methoden*. Berlin, Boston: De Gruyter, 1994. ISBN: 9783110902990. DOI: doi:10.1515/9783110902990. URL: https://doi.org/10.1515/9783110902990.

[Epa69] V. A. Epanechnikov. „Non-Parametric Estimation of a Multivariate Probability Density“. In: *Theory of Probability & Its Applications* 14.1 (1969), S. 153–158.

[FD81] David Freedman und Persi Diaconis. „On the Histogram as a Density Estimator: L2 Theory“. In: *Zeitschrift für Wahrscheinlichkeitstheorie und Verwandte Gebiete* 57.4 (1981), S. 453–476.

[Nad64] E. A. Nadaraya. „On Estimating Regression“. In: *Theory of Probability & Its Applications* 9.1 (1964), S. 141–142.

Literaturverzeichnis II

[Ros56] Murray Rosenblatt. „Remarks on Some Nonparametric Estimates of a Density Function“. In: *The Annals of Mathematical Statistics* 27.3 (1956), S. 832–837.

[Sco79] David W. Scott. „On Optimal and Data-Based Histograms“. In: *Biometrika* 66.3 (1979), S. 605–610.

[Sen68] Pranab Kumar Sen. „Estimates of the Regression Coefficient Based on Kendall's Tau“. In: *Journal of the American Statistical Association* 63.324 (1968), S. 1379–1389.

[Sil86] Bernard W. Silverman. *Density Estimation for Statistics and Data Analysis*. Monographs on Statistics and Applied Probability. London: Chapman und Hall, 1986. ISBN: 978-0412246203.

Literaturverzeichnis III

[The50] Henri Theil. „A Rank-Invariant Method of Linear and Polynomial Regression Analysis“. In: *Proceedings of the Koninklijke Nederlandse Akademie van Wetenschappen* 53 (1950), S. 386–392, 521–525, 1397–1412.

[Wat64] Geoffrey S. Watson. „Smooth Regression Analysis“. In: *Sankhyā: The Indian Journal of Statistics, Series A* 26.4 (1964), S. 359–372.