Einführung in die Kerndichteschätzung

Yavuzâlp Dal

Stand: 9. Februar 2026

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Parametrische vs. Nichtparametrische Dichteschätzung (Übersicht)

Parametrisch (kennen wir schon $\rightarrow$ Stochastik)

- Annahme: Verteilung ist bekannt!
- Wenige Parameter (μ, σ^2)
- Schätzung durch Parameterschätzer wie bspw. Maximum-Likelihood

Parametrische vs. Nichtparametrische Dichteschätzung (Übersicht)

Parametrisch (kennen wir schon $\rightarrow$ Stochastik)

- Annahme: Verteilung ist bekannt!
- Wenige Parameter (μ, σ^2)
- Schätzung durch Parameterschätzer wie bspw. Maximum-Likelihood

Nichtparametrisch (KDE)

- Keine feste Form; die Zufallsvariable X muss aber stetig sein, die Dichte f eine "glatte" Funktion
- Schätzung: Kern (wie bspw. Epanechnikov) sowie Bandbreite h
- Erfolgt mittels des Kerndichteschätzers

Modellannahme vs. Datengetrieben

$\longleftrightarrow$

Einfachheit vs. Flexibilität

$\longleftrightarrow$

Einleitung & Motivation

Warum nichtparametrisch? [BT94]

- Klassische parametrische Verfahren (z. B. unter Annahme einer Normalverteilung) sind oft zu starr.
  - Starke Kopplung an unsicheren Annahmen!
- Bei unbekannter Verteilung bietet die nichtparametrische Schätzung oft bessere Einblicke in die Datenstruktur.

Einleitung & Motivation

Warum nichtparametrisch? [BT94]

- Klassische parametrische Verfahren (z. B. unter Annahme einer Normalverteilung) sind oft zu starr.
  - Starke Kopplung an unsicheren Annahmen!
- Bei unbekannter Verteilung bietet die nichtparametrische Schätzung oft bessere Einblicke in die Datenstruktur.

Zielsetzung:

- Annäherung an den Wert $f(x)$ an einer Stelle x, ohne eine spezifische parametrische Familie vorauszusetzen.

Ausgangssituation

Gegeben seien u.u.i.d. Zufallsvariablen

$$X_1, \ldots, X_n \sim F \quad \text{mit unbekannter Dichte } f.$$

Zielsetzung:

$$\text{Schätze } f(x) \text{ oder } m(x) = \mathbb{E}(Y|X = x)$$

ohne Annahme einer parametrischen Familie.

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Empirische Verteilungsfunktion

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{\{X_i \leq x\}}$$

- Konsistent für F
- Aber: Treppenfunktion

Wie erhalten wir daraus eine Dichte?

Der Rosenblatt-Schätzer (Die theoretische Basis)

- **Idee:** Da $f(x) = F'(x)$, nutzt man den Differenzenquotienten der empirischen Verteilungsfunktion F_n.

Der Rosenblatt-Schätzer (Formel)

- **Der Schätzer:**

$$f_n(x) = \frac{F_n(x+h) - F_n(x-h)}{2h} \tag{1}$$

Der Rosenblatt-Schätzer (Konsistenz)

- **Konsistenz:** Damit der Schätzer gegen die wahre Dichte konvergiert, muss für $n \to \infty$ gelten:
  - Die Bandbreite $h \to 0$ (Bias reduzieren).
  - $nh \to \infty$ (Varianz reduzieren).

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Das Histogramm (Der Klassiker)

- **Funktionsweise:** Zerlegung des Datenraums in Boxen (Bins) der Breite h. Die Höhe der Box entspricht der relativen Häufigkeit $\frac{n_k}{n}$ normiert durch h.
- **Formal:**

$$\hat{f}_H(x) = \sum_k \frac{n_k}{nh} \mathbb{1}_{B_k}(x)$$

Das Histogramm (Probleme)

- **Probleme:**
  - Unstetigkeit: Die geschätzte Dichte ist eine Treppenfunktion.
  - Subjektivität: Abhängig von x_0 und h.

Das Histogramm (Optimale Bandbreite)

- **Optimale Bandbreite (h):**
  - Scott: $h \approx 3.49 s n^{-1/3}$
  - Freedman-Diaconis: $h^* = 2(x_{0.75} - x_{0.25}) n^{-1/3}$

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Grundidee der Kerndichteschätzung

- Jede Beobachtung trägt zur Schätzung an der Stelle x bei
- Der Beitrag hängt vom Abstand zu x ab

- Einführung einer Gewichtungsfunktion (Kernfunktion)
- Glättung statt harter Intervallabgrenzung

Kernschätzer (KDE) - Einführung

- **Der Schätzer:**

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right) \tag{2}$$

- K: Kernfunktion
- $h > 0$: Bandbreite

Kernschätzer (KDE) - Wahl des Kerns

- **Kernwahl:** Der Kern muss zu 1 integrieren ($\int K(x)dx = 1$).
- Gängige Kerne:
  - Rechteck-Kern
  - Gauß-Kern
  - Epanechnikov-Kern

Kernfunktion – Eigenschaften

- $K(x) \geq 0$
- $\int K(x)\,dx = 1$
- Symmetrisch um 0

- Bestimmt die Form der Glättung
- Einfluss meist geringer als der der Bandbreite

Kernschätzer (KDE) - Bandbreitenwahl

- **Bandbreitenwahl (Silverman's Rule):**

$$h_{opt} \approx 1.06\sigma n^{-1/5} \tag{3}$$

Kerndichteschätzung – Rolle der Bandbreite

- Kleine Bandbreite: geringe Glättung, hohe Varianz
- Große Bandbreite: starke Glättung, hoher Bias
- Zentrale Stellgröße der Kerndichteschätzung

KDE als Faltung

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \quad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right)$$

KDE als Faltung

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \quad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right)$$

$$\mathbb{E}[\hat{f}_n(x)] = (K_h * f)(x)$$

Bias = Glättungsfehler der Faltung

KDE als Faltung

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \quad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right)$$

KDE als Faltung

$$\hat{f}_n(x) = \int K_h(x-y)\, dF_n(y), \quad K_h(t) = \frac{1}{h} K\left(\frac{t}{h}\right)$$

$$\mathbb{E}[\hat{f}_n(x)] = (K_h * f)(x)$$

Bias = Glättungsfehler der Faltung

Bias–Varianz-Tradeoff

Unter Regularitätsannahmen:

$$\mathrm{Bias}(\hat{f}_n(x)) = O(h^2), \quad \mathrm{Var}(\hat{f}_n(x)) = O\left(\frac{1}{nh}\right)$$

Bias–Varianz-Tradeoff

Unter Regularitätsannahmen:

$$\mathrm{Bias}(\hat{f}_n(x)) = O(h^2), \quad \mathrm{Var}(\hat{f}_n(x)) = O\left(\frac{1}{nh}\right)$$

$$\mathrm{MSE}(x) = O(h^4) + O\left(\frac{1}{nh}\right)$$

$h_{\mathrm{opt}} \sim n^{-1/5}$

Bezug zum Rosenblatt-Schätzer

- Rosenblatt-Schätzer als Spezialfall
- Rechteckkern mit kompakter Unterstützung

- Kerndichteschätzung verallgemeinert den Ansatz
- Liefert stetige Schätzfunktionen

Vorteile der Kerndichteschätzung

- Stetige und glatte Schätzfunktion
- Flexibel einsetzbar
- Gute theoretische Eigenschaften
- Grundlage für weiterführende nichtparametrische Verfahren

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Nichtparametrische Regression – Einführung

Nadaraya–Watson-Schätzer:

$$\hat{m}_{NW}(x) = \frac{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right) Y_i}{\sum_{i=1}^{n} K\left(\frac{x-X_i}{h}\right)} \tag{4}$$

- Schätzung von $m(x)$ als gewichteter Mittelwert der umliegenden Y-Werte.

Nichtparametrische Regression – Zielsetzung

Ziel:

- Schätzung des funktionalen Zusammenhangs zwischen X und Y
- Ohne Annahme einer konkreten parametrischen Form für $m(x)$

Unterschied zur linearen Regression:

- Kein globales lineares Modell
- Lokale Anpassung an die Datenstruktur

Nichtparametrische Regression – Lokale Glättung

Grundidee:

- Punkte mit ähnlichen X-Werten liefern ähnliche Informationen über $m(x)$
- Beobachtungen in der Nähe von x werden stärker gewichtet

Umsetzung:

- Gewichtung erfolgt über eine Kernfunktion K
- Die Bandbreite h bestimmt die Größe der lokalen Umgebung

Nadaraya–Watson-Schätzer – Interpretation

Interpretation des Schätzers:

- $\hat{m}_{NW}(x)$ ist ein gewichteter Mittelwert der Y_i
- Gewichte hängen vom Abstand zwischen X_i und x ab

Eigenschaft:

- Je näher X_i an x liegt, desto größer ist sein Einfluss

Nichtparametrische Regression – Rolle der Bandbreite

Einfluss der Bandbreite h:

- Kleines h: starke lokale Anpassung, hohe Varianz
- Großes h: starke Glättung, höherer Bias

Analogie zur Dichteschätzung:

- Gleicher Bias-Varianz-Tradeoff wie bei der KDE

Nichtparametrische Regression – Vorteile und Grenzen

Vorteile:

- Hohe Flexibilität
- Keine Modellfehlanpassung durch falsche Annahmen

Grenzen:

- Wahl der Bandbreite entscheidend
- Randprobleme bei kleinen Stichproben

Zusammenhang zur Kerndichteschätzung

Gemeinsames Prinzip:

- Verwendung von Kernfunktionen
- Lokale Gewichtung von Beobachtungen

Unterschied:

- Dichteschätzung: Schätzung von $f(x)$
- Regression: Schätzung von $m(x) = \mathbb{E}(Y|X = x)$

Strukturelle Sicht

$$m(x) = \frac{\int y\, f_{XY}(x,y)\, dy}{f_X(x)}$$

$$\hat{m}(x) = \frac{\hat{r}(x)}{\hat{f}_X(x)}, \quad \hat{r}(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right) Y_i$$

Quotient von Kerndichteschätzern

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Robuste Lineare Regression – Zielsetzung

Ziel:

- Schätzung eines linearen Zusammenhangs zwischen X und Y
- Geringe Empfindlichkeit gegenüber Ausreißern

Motivation:

- Klassische lineare Regression basiert auf quadratischen Fehlern
- Einzelne Ausreißer können die Schätzung stark verzerren

Robuste Lineare Regression – Grundidee

Zentrale Idee:

- Betrachtung von Steigungen zwischen Beobachtungspaaren
- Verzicht auf Minimierung einer globalen Fehlerfunktion

Konsequenz:

- Schätzung basiert auf Lageparametern (Median)
- Hohe Robustheit gegenüber extremen Werten

Robuste Lineare Regression – Rolle des Medians

Warum der Median?

- Unempfindlich gegenüber einzelnen Ausreißern
- Repräsentiert die zentrale Tendenz der Steigungen

Vergleich:

- Mittelwert: stark ausreißerempfindlich
- Median: robust gegenüber extremen Beobachtungen

Robuste Regression vs. Kleinste Quadrate

Methode der kleinsten Quadrate:

- Minimiert die Summe der quadrierten Residuen
- Sehr empfindlich gegenüber Ausreißern

Theil- bzw. Theil–Sen-Schätzer:

- Basieren auf Medianschätzung
- Deutlich robuster gegenüber Ausreißern

Theil–Sen-Schätzer – Eigenschaften

Wichtige Eigenschaften:

- Hoher Breakdown-Point
- Konsistent unter milden Voraussetzungen
- Geeignet bei verrauschten Daten

Einsatzgebiet:

- Explorative Datenanalyse
- Datensätze mit möglichen Ausreißern

Robuste Lineare Regression – Grenzen

Einschränkungen:

- Höherer Rechenaufwand bei großen Stichproben
- Beschränkt auf lineare Zusammenhänge

Abgrenzung:

- Nichtparametrische Regression bietet höhere Flexibilität
- Dafür geringere Interpretierbarkeit

Robuste Lineare Regression (Theil-Schätzer) - Einführung

- **Theil-Methode I:** Steigung zwischen Paaren $(i, i + n/2)$, Median als Schätzer.
- **Theil-Sen-Schätzer (Methode II):** Median der Steigungen zwischen allen Paaren $i < j$:

Robuste Lineare Regression (Theil-Schätzer) - Formel

$$H_{ij} = \frac{Y_j - Y_i}{X_j - X_i} \tag{5}$$

- Der Schätzer für den Anstieg β ist der Median dieser Steigungen.

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Take-Home Messages

- Nichtparametrisch = lokal + datengetrieben
- KDE = Faltung mit empirischem Maß
- Bandbreite bestimmt Konvergenz
- Regression folgt demselben Prinzip
- Robustheit schützt vor Ausreißern

Fazit und Ausblick

- **Flexibilität:** Nichtparametrische Methoden passen sich den Daten an.
- **Parameter h:** Kritischer Schritt, Balance zwischen Bias und Varianz.

Fazit und Ausblick (Fortsetzung)

- **Robustheit:** Verfahren wie der Theil-Sen-Schätzer bieten robuste Alternativen zur klassischen Regression, besonders bei Ausreißern.

Outline

1. Einleitung & Motivation
2. Der Rosenblatt-Schätzer
3. Das Histogramm
4. Kernschätzer (KDE)
5. Nichtparametrische Regression
6. Robuste Lineare Regression
7. Zusammenfassung
8. Literaturverzeichnis

Literaturverzeichnis I

[BT94] Herbert Büning und Götz Trenkler. *Nichtparametrische statistische Methoden*. Berlin, Boston: De Gruyter, 1994. ISBN: 9783110902990. DOI: doi:10.1515/9783110902990. URL: https://doi.org/10.1515/9783110902990.